МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»

РТУ МИРЭА
Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)
09.03.03 Прикладная информатика

КУРСОВАЯ РАБОТА
по дисциплине «Языки программирования для статистической обработки данных»

Тема: «Разработка программы классификации данных на базе полносвязной нейронной сети прямого распространения в целях выявления мошеннических действий с кредитными картами»

ФИО студента: Скорик Елизавета Витальевна
Группа: ИНБО-20-24
Руководитель курсовой работы: ст. преподаватель Трушин С.М.

Москва 2026 г.

1.А. Введение

РТУ МИРЭА

Актуальность

В условиях стремительного роста цифровых технологий объёмы транзакций по банковским картам постоянно увеличиваются. Однако вместе с удобством безналичных расчётов растёт и число мошеннических действий, направленных на хищение средств. Традиционные методы контроля, такие как простые правила или пороговые значения, часто оказываются недостаточно эффективными при обработке больших массивов данных. Именно поэтому сегодня возникает потребность в интеллектуальных методах анализа, способных автоматически выявлять подозрительные операции.



Объект и предмет исследования

- Объектом исследования выступают транзакции по кредитным картам
- Предметом исследования являются методы классификации данных, используемые для обнаружения мошеннических операций.

1.Б. Введение

Цель работы

Разработать программу классификации данных на основе полносвязной нейронной сети прямого распространения, предназначенной для выявления мошеннических действий с кредитными картами.

Задачи

Для достижения этой цели необходимо решить следующие задачи:

- рассмотреть предметную область и особенности анализа транзакционных данных;
- изучить основные методы статистической обработки данных;
- провести обзор инструментов анализа данных, включая язык R и систему Glarus BI;
- разработать модель классификации на основе нейронной сети;
- реализовать программное решение и оценить его эффективность.

1.B. Введение

Методы

- Описательная статистика (среднее, медиана, дисперсия)
- Проверка статистических гипотез (t-тест, хи-квадрат)
- Отбор признаков: Mutual Information (MI) и Information Value (IV)
- Логистическая регрессия
- Полносвязная нейронная сеть прямого распространения (с весами классов для борьбы с дисбалансом)



Ожидаемый результат

В итоге должна быть создана программа, способная с достаточной точностью выявлять мошеннические транзакции, что позволит повысить уровень безопасности финансовых операций и снизить убытки от мошенничества.

2.А. Источник данных

РТУ МИРЭА

- Источник: Kaggle, симулятор Sparkov Data Generation
- 1 604 294 транзакции (пользователи из США)
- 22 исходных поля
- Целевая переменная: is_fraud (0 – легальная, 1 – мошенническая)
- Сильный дисбаланс классов (~0,5% мошеннических)

	trans_date_trans_time	cc_num	merchant	category	amt	first	last	gender	street	city	...	lat	long	city_pop	job	dob	trans_num	unix_time	merch_lat	merch_long	is_fraud
	<chr>	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	...	<chr>	<chr>	<int>	<chr>	<chr>	<chr>	<int>	<chr>	<chr>	<int>
1	2020-06-21 12:14:25	2.291164e+15	fraud_Kirlin and Sons	personal_care	2.86	Jeff	Elliott	M	351 Darlene Green	Columbia	...	33.9659	-80.9355	333497	Mechanical engineer	1968-03-19	2da90c7d74bd46a0caf3777415b3ebd3	1371816865	33.986391	-81.200714	0
2	2020-06-21 12:14:33	3.573030e+15	fraud_Sporer-Keebler	personal_care	29.84	Joanne	Williams	F	3638 Marsh Union	Altonah	...	40.3207	-110.436	302	Sales professional, IT	1990-01-17	324cc204407e99f51b0d6ca0055005e7	1371816873	39.450497999999996	-109.960431	0
3	2020-06-21 12:14:53	3.598215e+15	fraud_Swaniawski, Nitzsche and Welch	health_fitness	41.28	Ashley	Lopez	F	9333 Valentine Point	Bellmore	...	40.6729	-73.5365	34496	Librarian, public	1970-10-21	c81755dbbbea9d5c77f094348a7579be	1371816893	40.49581	-74.196111	0
4	2020-06-21 12:15:15	3.591920e+15	fraud_Haley Group	misc_pos	60.05	Brian	Williams	M	32941 Krystal Mill Apt. 552	Titusville	...	28.5697	-80.8191	54767	Set designer	1987-07-25	2159175b9efe66dc301f149d3d5abf8c	1371816915	28.812397999999998	-80.883061	0
5	2020-06-21 12:15:17	3.526826e+15	fraud_Johnston-Casper	travel	3.19	Nathan	Massey	M	5783 Evan Roads Apt. 465	Falmouth	...	44.2529	-85.01700000000001	1126	Furniture designer	1955-07-06	57ff021bd3f328f8738bb535c302a31b	1371816917	44.959148	-85.884734	0
6	2020-06-21 12:15:37	3.040768e+13	fraud_Daugherty LLC	kids_pets	19.55	Danielle	Evans	F	76752 David Lodge Apt. 064	Breesport	...	42.1939	-76.7361	520	Psychotherapist	1991-10-13	798db04aaceb4febd084f1a7c404da93	1371816937	41.747157	-77.584197	0
7	2020-06-21 12:15:44	2.131807e+14	fraud_Romaguera Ltd	health_fitness	133.93	Kayla	Sutton	F	010 Weaver Land	Carlotta	...	40.507	-123.9743	1139	Therapist, occupational	1951-01-15	17003d7ce534440eadb10c4750e020e5	1371816944	41.499458000000004	-124.888729	0
8	2020-06-21 12:15:50	3.589290e+15	fraud_Reichel LLC	personal_care	10.37	Paula	Estrada	F	350 Stacy Glens	Spencer	...	43.7557	-97.5936	343	Development worker, international aid	1972-03-05	8be473af4f05fc6146ea55ace73e7ca2	1371816950	44.495498	-97.728453	0
9	2020-06-21 12:16:10	3.596357e+15	fraud_Goyette, Howell and Collier	shopping_pos	4.37	David	Everett	M	4138 David Fall	Morrisdale	...	41.0001	-78.2357	3688	Advice worker	1973-05-27	71a1da150d1ce510193d7622e08e784e	1371816970	41.546067	-78.120238	0
10	2020-06-21 12:16:11	3.546898e+15	fraud_Kilback Group	food_dining	66.54	Kayla	Obrien	F	7921 Robert Port Suite 343	Prairie Hill	...	31.6591	-96.8094	263	Barrister	1956-05-30	a7915132c7c4240996ba03a47f81e3bd	1371816971	31.782919	-96.366185	0

2.Б. Источник данных

Столбцы:

- trans_date_trans_time — дата и время транзакции;
- cc_num — номер кредитной карты клиента;
- merchant — название торговой точки;
- category — категория торговой точки;
- amt — сумма транзакции;
- first — имя владельца кредитной карты;
- last — фамилия владельца кредитной карты;
- gender — пол владельца кредитной карты;
- street — улица адреса владельца кредитной карты;
- city — город владельца кредитной карты;
- state — штат владельца кредитной карты;
- zip — почтовый индекс владельца кредитной карты;
- lat — широта местоположения владельца кредитной карты;
- long — долгота местоположения владельца кредитной карты;
- city_pop — население города владельца кредитной карты;
- job — профессия владельца кредитной карты;
- dob — дата рождения владельца кредитной карты;
- trans_num — номер транзакции;
- unix_time — время транзакции в формате UNIX;
- merch_lat — широта местоположения торговой точки;
- merch_long — долгота местоположения торговой точки;
- is_fraud —целевая переменная.

3.А. Инструменты анализа

РТУ МИРЭА

Glarus BI

Библиотеки языка **R**:

- tidyverse (включая dplyr, ggplot2) – обработка и визуализация данных
- lubridate – работа с датой и временем
- praznik – расчёт взаимной информации (Mutual Information)
- Information – расчёт Information Value (IV) и WoE
- corrplot – визуализация корреляционной матрицы
- maps, sf – построение географических тепловых карт
- keras (с TensorFlow) – создание и обучение нейронной сети
- rmarkdown (и knitr) – автоматическая генерация отчётов





3.Б. Инструменты анализа

Критерий	R	Glarus BI
Основное назначение	Статистический анализ, машинное обучение	Бизнес-аналитика, интерактивные дашборды
Подход	Программирование	No-code
Статистические методы	t-тест, хи-квадрат, MI, IV, регрессии, нейронные сети и др.	Базовые агрегации (сумма, среднее, счёт)
Машинное обучение	Полноценное: нейронные сети (keras), случайный лес, SVM, градиентный бустинг	Отсутствует
Автоматизация отчётности	RMarkdown	Экспорт дашбордов в PDF/PNG
Гибкость визуализации	Полный контроль (ggplot2, слои, темы, любые модификации)	Высокая – библиотека готовых виджетов (карты, деревья, графики), но в рамках интерфейса
Использование	Для исследовательского анализа, моделирования и технических отчётов	Для оперативных дашбордов и презентаций агрегированных результатов руководству

4. Предобработка данных

- Проверка на пропуски и дубликаты – отсутствуют
- Коррекция типов данных (числовые, даты, факторы)
- Создание новых признаков:
  - месяц, день недели, час транзакции
  - возраст клиента на момент операции
  - расстояние между клиентом и торговой точкой (формула гаверсинуса)
- Тригонометрическое преобразование часа (hour_sin, hour_cos) для учёта цикличности

```
Количество дубликатов:  0
Количество пропусков:  0
```

age <dbl>	month <dbl>	day_of_week <dbl>	hour <int>	purchase_dist <dbl>
52	6	7	12	24.56159
30	6	7	12	104.92562
49	6	7	12	59.08037
32	6	7	12	27.69871

```
Ошибка в широте клиента:  FALSE
Ошибка в широте торговой точке:  FALSE
Ошибка в долготе клиента:  FALSE
Ошибка в долготе торговой точке:  FALSE
Ошибка в возрасте:  FALSE
Ошибка в сумме:  FALSE
```

5.A. Исследовательский анализ данных

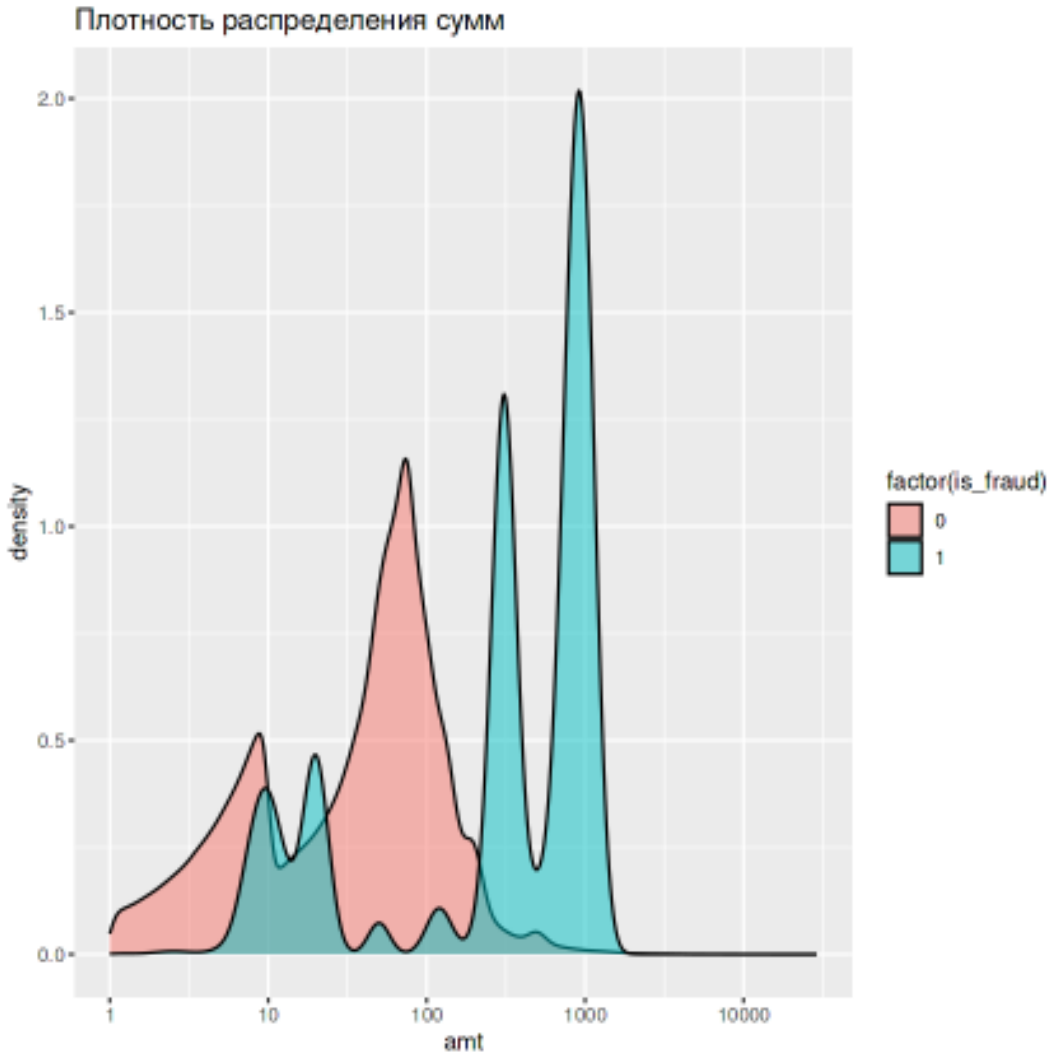
РТУ МИРЭА

О чём график:

Сравнение распределения сумм легальных и мошеннических операций (логарифмическая шкала).

Мини-выводы:

- Большинство легальных транзакций имеют сумму до 200$.
- Мошеннические операции, напротив, концентрируются в диапазоне 900–1100,хотявстречаютсяимелкие(5–50,хотявстречаютсяимелкие(5–50).



5.Б. Исследовательский анализ данных

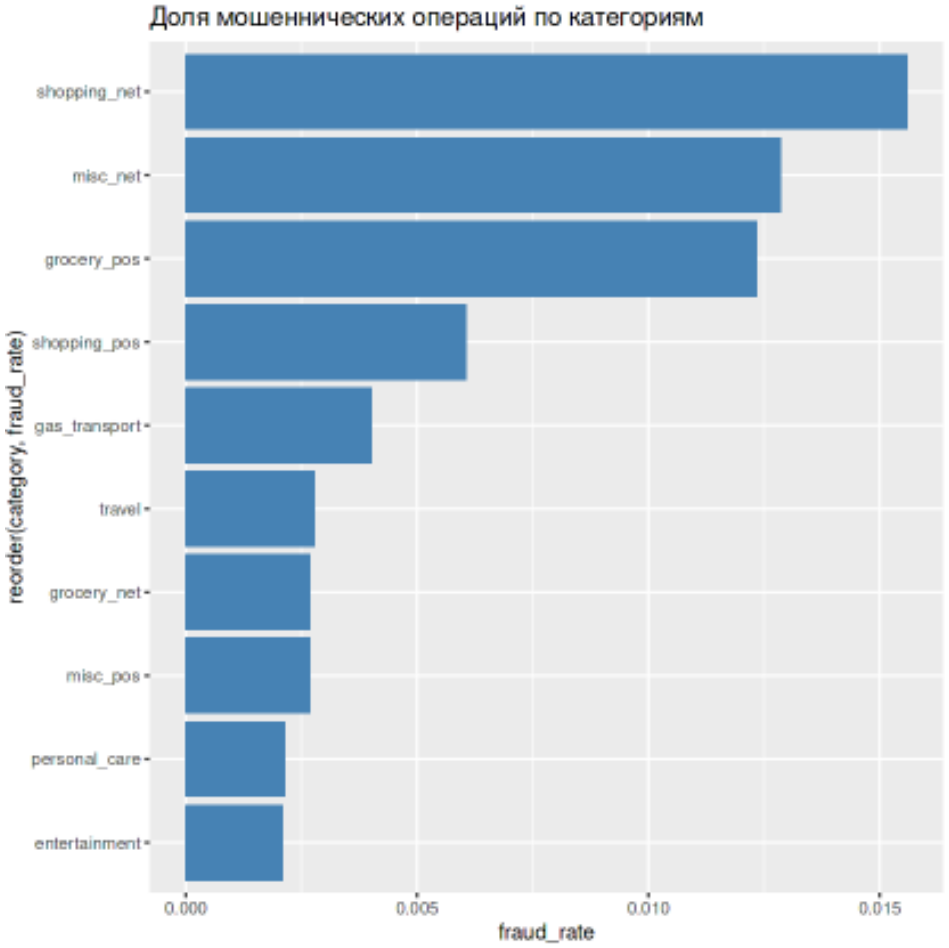
РТУ МИРЭА

О чём график:

Топ-10 категорий торговых точек с наибольшей долей мошеннических операций.

Мини-выводы:

- Лидируют онлайн-категории (например, «online shopping», «digital goods») – мошенники предпочитают бесконтактные каналы.
- Продуктовые магазины (офлайн) также входят в тройку – возможно, из-за кражи физических карт или данных с чеков.



5.B. Исследовательский анализ данных

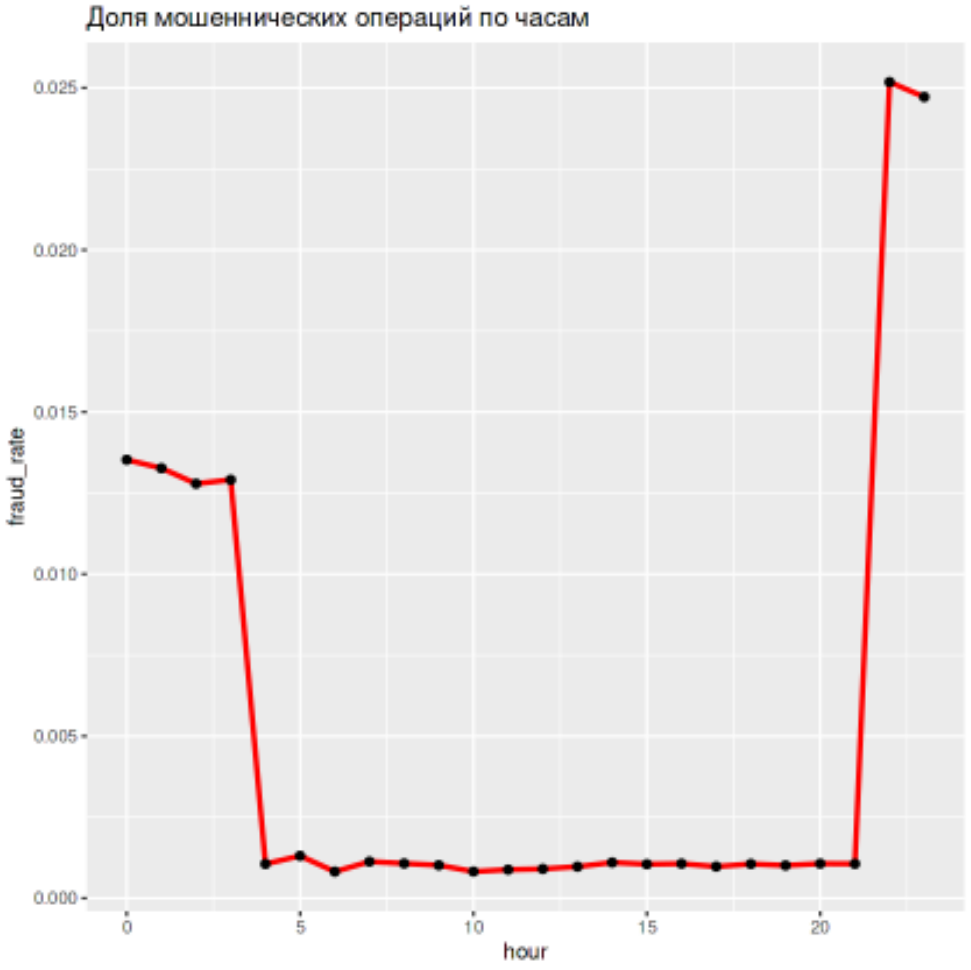
РТУ МИРЭА

О чём график:

Линейный график, показывающий долю мошеннических транзакций (в % от всех операций) в зависимости от часа суток.

Мини-выводы:

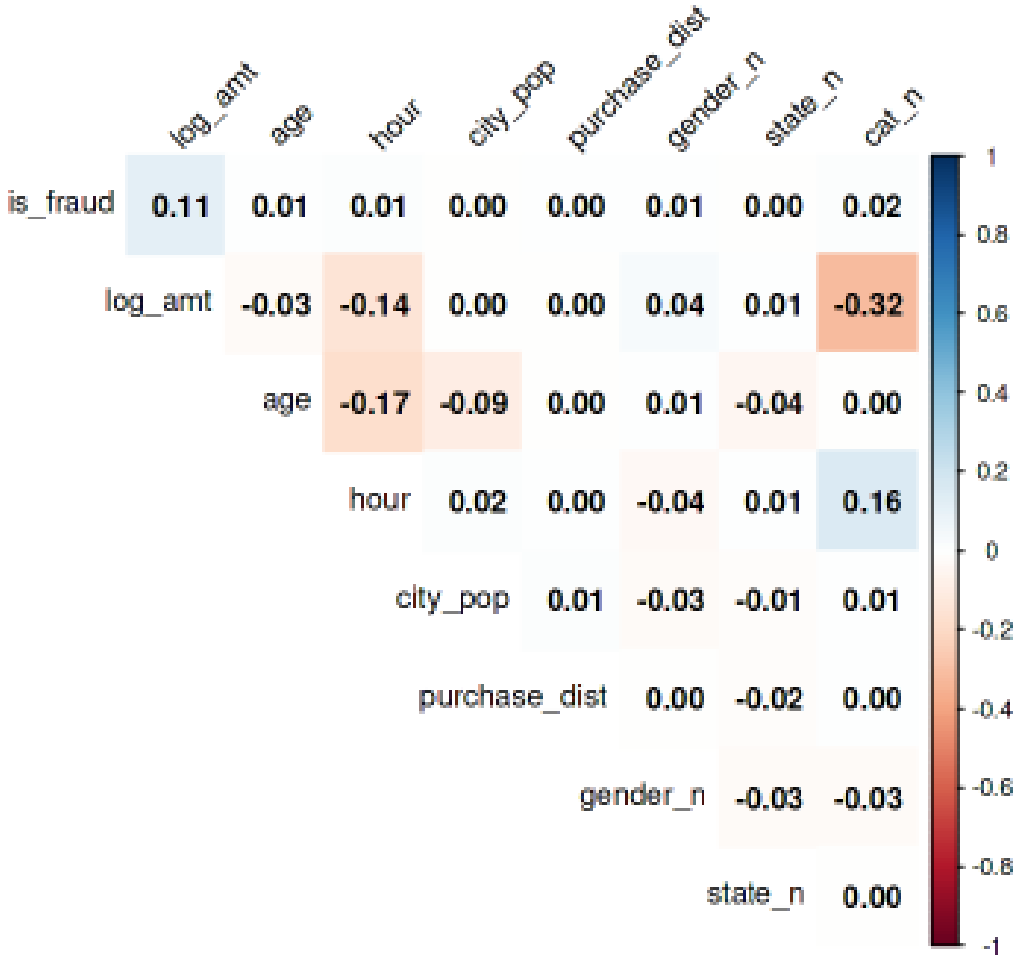
- Мошенническая активность резко возрастает в ночное время – с 22:00 до 3:00.
- В этот период доля фрода достигает 2,5%, тогда как в остальные часы стабильно держится на уровне около 0,1%.
- Время совершения транзакции – сильный предиктор мошенничества, что обосновывает включение циклических признаков hour_sin и hour_cos в модель.



6. Корреляционный анализ

Матрица корреляции Пирсона показала слабую линейную связь между признаками и is_fraud (только log_amt ~0.1)

Причина: нелинейный характер зависимостей



7. Отбор признаков

MI – улавливает любые типы зависимостей (не только линейные)
IV – банковский стандарт оценки предсказательной силы

Результаты (топ признаков):

- amt (IV = 3.30) – абсолютный лидер
- hour (IV = 1.7)
- merchant и category (IV ~0.7–0.8)

Признаки, отобранные для модели: log_amt, category, hour_sin, hour_cos, age

	Variable	IV	MI
1	amt	3.3002934364	1.027518e-02
2	hour	1.7225413122	4.510389e-03
3	merchant	0.8324633481	2.068471e-03
4	category	0.7487471783	1.882160e-03
5	month	0.0953104676	2.508467e-04
6	age	0.0508740173	1.464918e-04
7	state	0.0375376470	9.782743e-05
8	day_of_week	0.0273657812	6.877930e-05
9	gender	0.0064967870	1.644473e-05
10	city_pop	0.0055295475	2.285070e-05
11	purchase_dist	0.0005140231	4.271892e-06

8. Проверка гипотез

РТУ МИРЭА

t-тест Уэлча

H_0 : Средние суммы легальных и мошеннических транзакций одинаковы.

H_1 : Средние суммы существенно различаются.

Отвергаем H₀. Мошеннические транзакции в среднем имеют существенно бóльшую сумму, чем легальные.

```
        Welch Two Sample t-test

data:  amt by is_fraud
t = -106.53, df = 8162.8, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -470.8748 -453.8595
sample estimates:
mean in group 0 mean in group 1
       67.62292       529.99007
```

Критерий хи-квадрат Пирсона

H_0: Категория покупки и мошенничество не связаны.

H_1 : Между категорией и фродом существует статистически значимая связь.

Отвергаем H₀. Определённые категории являются более рискованными.

```
        Pearson's Chi-squared test

data:  contingency_table
X-squared = 7092.7, df = 13, p-value < 2.2e-16
```

9. Логистическая регрессия

Включены признаки: log_amt, category, hour_sin, hour_cos, age

Использованы веса классов для борьбы с дисбалансом

Коэффициенты показывают: рост суммы, ночные часы, онлайн-категории увеличивают риск

```
Call:
glm(formula = is_fraud ~ log_amt + category + hour_sin + hour_cos +
    age + gender, family = "binomial", data = model_data, weights = weights)

Coefficients:
                     Estimate Std. Error  z value Pr(>|z|)
(Intercept)          -2.835832   0.007951 -356.644  < 2e-16 ***
log_amt               1.119903   0.001786  627.035  < 2e-16 ***
categoryfood_dining   0.408766   0.010263   39.830  < 2e-16 ***
categorygas_transport 2.235429   0.009298  240.411  < 2e-16 ***
categorygrocery_net   1.847758   0.011550  159.974  < 2e-16 ***
categorygrocery_pos   1.594010   0.008728  182.637  < 2e-16 ***
categoryhealth_fitness 0.832857  0.010446   79.729  < 2e-16 ***
categoryhome         -0.077348   0.009802   -7.891 2.99e-15 ***
categorykids_pets     1.051436   0.009524  110.394  < 2e-16 ***
categorymisc_net      1.458636   0.010033  145.390  < 2e-16 ***
categorymisc_pos      1.801841   0.010374  173.680  < 2e-16 ***
categorypersonal_care 1.250180   0.009818  127.330  < 2e-16 ***
categoryshopping_net  1.548819   0.009097  170.265  < 2e-16 ***
categoryshopping_pos  0.948729   0.009381  101.136  < 2e-16 ***
categorytravel        2.454956   0.012126  202.459  < 2e-16 ***
hour_sin             -0.408893   0.003613 -113.160  < 2e-16 ***
hour_cos              1.733441   0.002640  656.651  < 2e-16 ***
age                   0.061589   0.001580   38.971  < 2e-16 ***
genderM              -0.130029   0.003247  -40.050  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 4448047  on 1604293  degrees of freedom
Residual deviance: 2494909  on 1604275  degrees of freedom
AIC: 2489953

Number of Fisher Scoring iterations: 8
```

(Intercept): 0.0586697083877115 **log_amt:** 3.06455573598316 **categoryfood_dining:** 1.50496021501438 **categorygas_transport:** 9.35049119282301 **categorygrocery_net:** 6.34557399513426 **categorygrocery_pos:** 4.92345249472261 **categoryhealth_fitness:** 2.29988020190012 **categoryhome:** 0.925567318915518 **categorykids_pets:** 2.86175643261948 **categorymisc_net:** 4.30009088220949 **categorymisc_pos:** 6.0607951714263 **categorypersonal_care:** 3.49097210195782 **categoryshopping_net:** 4.70590849913733 **categoryshopping_pos:** 2.58242598207129 **categorytravel:** 11.6459167084388 **hour_sin:** 0.664385561442344 **hour_cos:** 5.6600970765376 **age:** 1.06352474685442 **genderM:** 0.878070122471749

10. Классификация

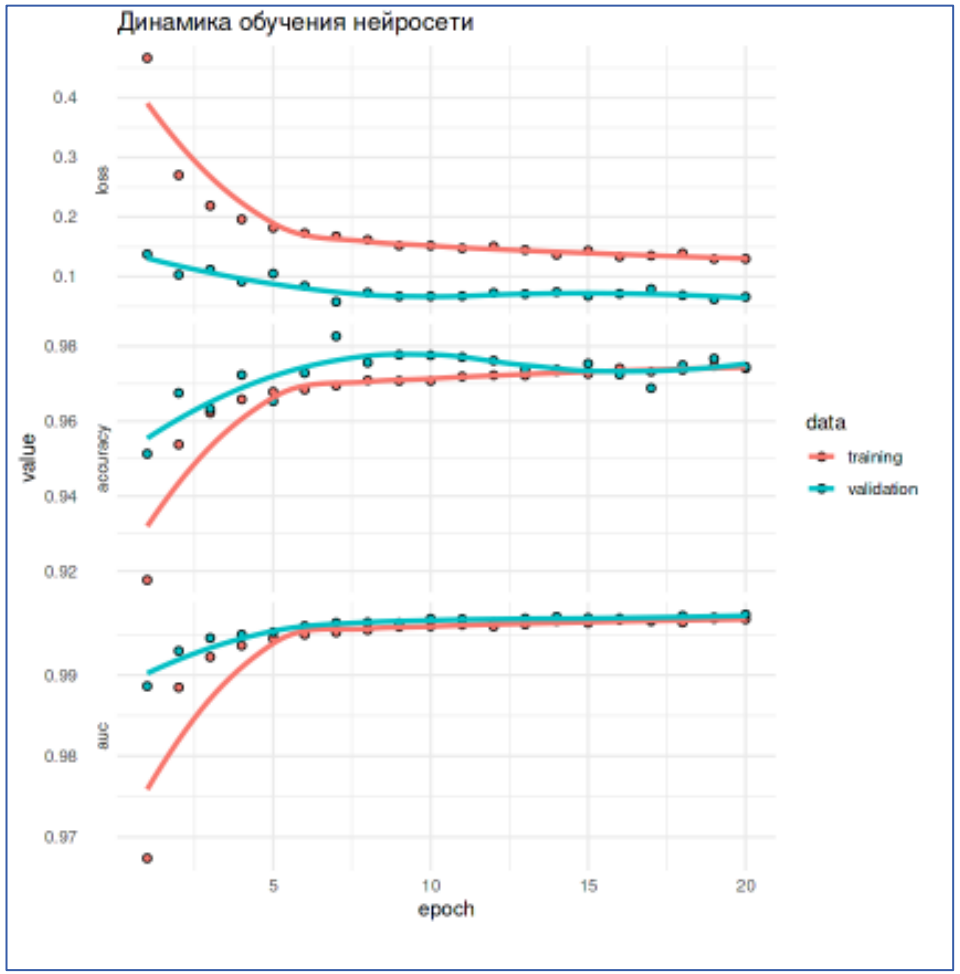
РТУ МИРЭА

Полносвязная нейронная сеть прямого распространения

- **AUC = 0.997** – исключительная разделяющая способность
- **Accuracy = 97.6%**
- **Recall = 98.2%** – выявлено 1672 из 1702 мошеннических операций в тесте
- **False Positive Rate ~2.6%** – допустимый компромисс в fraud-детекции
- Матрица ошибок: 98.2% фрода распознано, только 1.8% пропущено

	loss	accuracy	auc
	0.06205927	0.97652549	0.99721658

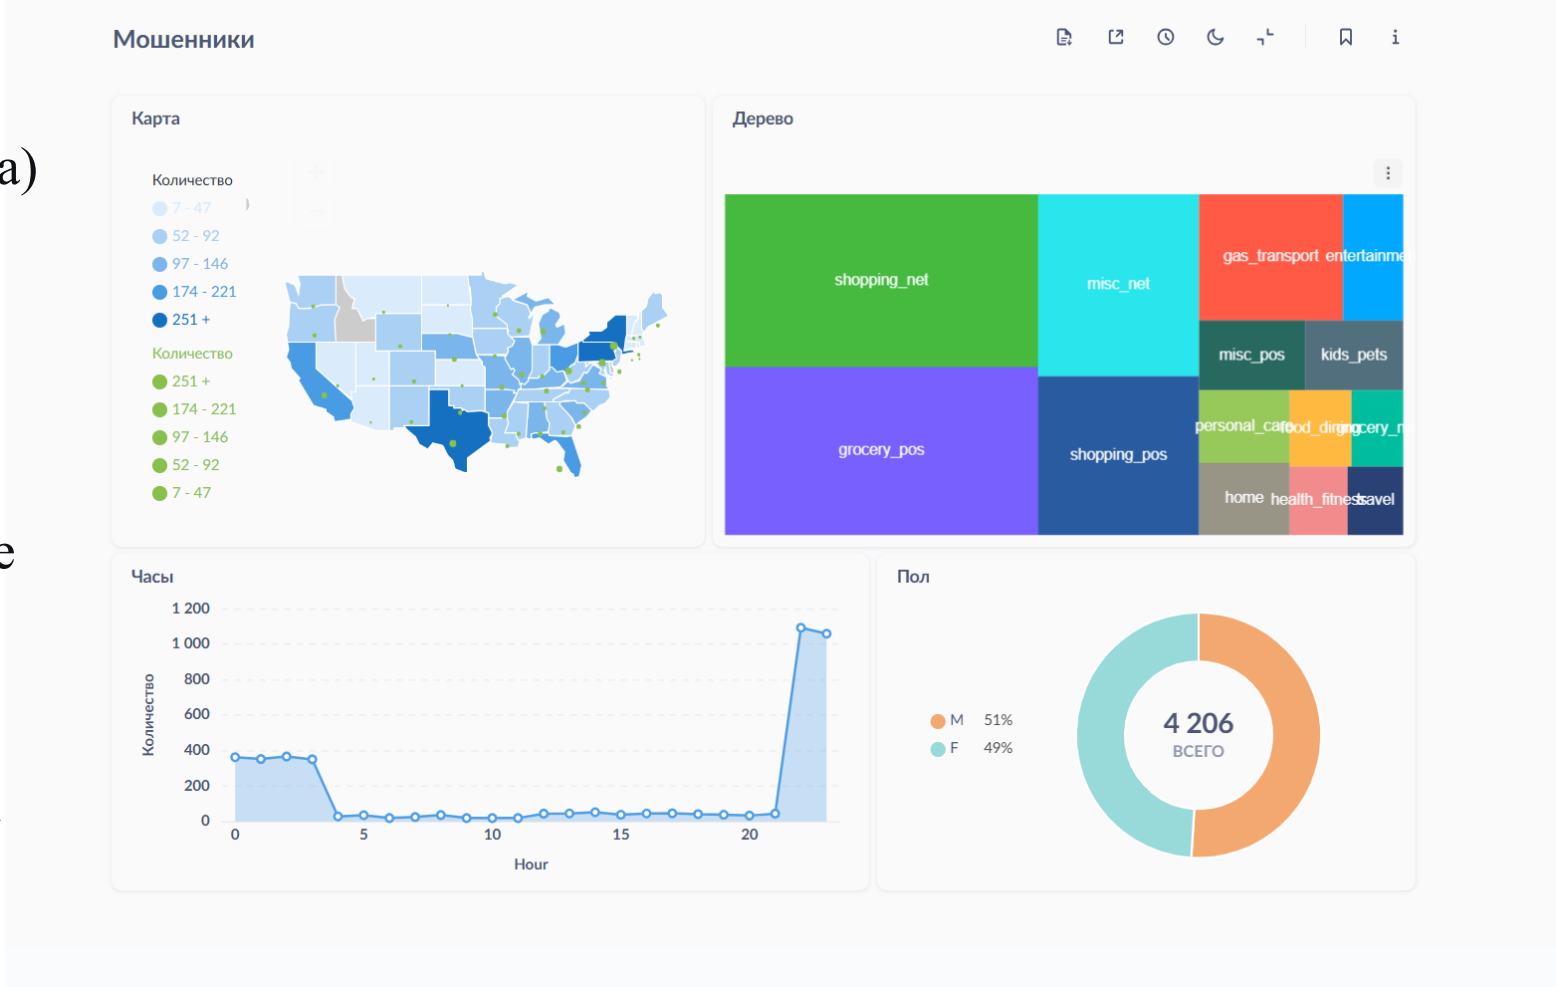
	Predicted	
Actual	0	1
0	310944	8213
1	30	1672



11. Визуализация в Glarus BI

Интерактивный дашборд в Glarus BI

- Карта плотности мошенничества по штатам США (пузырьковая диаграмма)
- Древовидная карта – топ категорий торговых точек по числу фрод-операций
- Линейный график – пик мошенничества с 22:00 до 03:00
- Кольцевая диаграмма – распределение пострадавших по полу



Вывод: Дашборд позволяет оперативно мониторить ключевые индикаторы риска без написания кода.

12. Выводы

РТУ МИРЭА

Ключевые результаты:

- Ключевые предикторы мошенничества: сумма транзакции (IV = 3,30), час операции (IV = 1,7), категория покупки
- Нейросетевая модель: AUC = 0,997, Recall = 98,2% (выявлено 1672 из 1702 фрод-операций)
- Связка R + Glarus BI — полный аналитический конвейер (исследование + интерактивные дашборды)



Практическая значимость:

Внедрение в системы anti-fraud для автоматической блокировки подозрительных транзакций в реальном времени

Перспективы:

- Сравнение с другими моделями (случайный лес, градиентный бустинг, SVM)
- Байесовская оптимизация гиперпараметров

Спасибо за внимание! Доклад окончен