МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

КУРСОВАЯ РАБОТА

по дисциплине «Языки программирования для статистической обработки данных»

Тема курсовой работы: «Разработка программы классификации данных на базе полносвязной нейронной сети прямого распространения в целях выявления мошеннических действий с кредитными картами»

Студент группы ИНБО-20-24	Скорик Елизавета Витальевна	(подпись)
Руководитель курсовой работы	ст. Преподаватель Трушин С.М.	(подпись)
Работа представлена к защите	«___»_____2026 г.	
Допущен к защите	«___»_____2026 г.	

Москва 2026 г.

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)

Утверждаю
Заведующий кафедрой ПМ
_____Саратова Т.Е.
(подпись)
«25» февраля 2026 г.

ЗАДАНИЕ
на выполнение курсовой работы

по дисциплине «Языки программирования для статистической обработки данных»

Студент Скорик Елизавета Витальевна Группа ИНБО-20-24

Тема «Разработка программы классификации данных на базе полносвязной нейронной сети прямого распространения в целях выявления мошеннических действий с кредитными картами»

Исходные данные: собранный студентом набор данных по теме работы
Перечень вопросов, подлежащих разработке, и обязательного графического материала:
Характеристика изучаемой предметной области, алгоритма, набора данных (описание текущего состояния исследуемой предметной области, выделение перспективных направлений исследований, применимость алгоритмов анализа и обработки данных, описание полей набора данных) Математическая формулировка предлагаемого метода анализа и обработки данных (классическая постановка задачи, формулировка задачи статистической обработки данных, описание параметров, описание критерия качества решения конечной задачи) Анализ полученной выборки данных с использованием предложенных методов анализа и обработки данных (описание последовательности действий или сценария обработки данных)
Построение визуализаций и качественных выводов по проделанной работе

Срок представления к защите курсовой работы: **до «30» мая 2026 г.**

Задание на курсовую работу выдал _____ Трушин С.М.
Подпись руководителя *(ФИО руководителя)*
«24» февраля 2026 г.

Задание на курсовую работу получил _____ Скорик Е.В.
Подпись обучающегося *(ФИО обучающегося)*
«24» февраля 2026 г.

АННОТАЦИЯ

Курсовая работа посвящена разработке системы обнаружения мошеннических операций с банковскими картами на основе методов машинного обучения и статистического анализа транзакционных данных. В ходе исследования проведён комплексный анализ датасета из более чем 1,6 млн записей, выполнена предобработка данных, отбор признаков с использованием методов Mutual Information и Information Value, а также проверка статистических гипотез. Разработанная полносвязная нейронная сеть прямого распространения продемонстрировала высокую эффективность классификации, достигнув значения AUC 0,993 при общей точности 96%. Проведено сравнение инструментов визуализации и отчётности: показано, что язык R обеспечивает гибкость в обработке больших данных и автоматизации анализа, тогда как платформа Glarus BI, несмотря на удобство интерфейса, имеет существенные ограничения по объёму и форматам импортируемых данных. Практическая значимость работы заключается в обосновании комбинированного подхода к построению аналитических систем, позволяющего повысить безопасность финансовых операций и снизить убытки от мошенничества.

Ключевые слова: анализ данных, обнаружение мошенничества, машинное обучение, полносвязная нейронная сеть, язык программирования R, Glarus BI, автоматизация отчётности, исследовательский анализ данных, статистическая проверка гипотез, RMarkdown.

Курсовая работа включает в себя 53 страницы, 26 рисунков и 16 листингов без Приложения. В Приложении содержится 20 рисунков, оно занимает 7 страниц.

СОДЕРЖАНИЕ

АННОТАЦИЯ 3
ВВЕДЕНИЕ 7
1 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ СТАТИСТИЧЕСКОЙ ОБРАБОТКИ ДАННЫХ 9
1.1 Описание предметной области 9
1.1.1 Значимость анализа данных в рассматриваемой области 9
1.1.2 Основные типы данных 9
1.1.3 Ключевые задачи статистического анализа 10
1.2 Основные методы статистической обработки данных 11
1.2.1 Описательная статистика 11
1.2.2 Методы проверки гипотез 11
1.2.3 Корреляционный анализ и регрессионное моделирование 12
1.2.4 Методы кластеризации и классификации 13
1.2.5 Примеры практического применения статистических методов 14
1.3 Язык программирования R и его возможности для статистического анализа 14
1.3.1 Основные преимущества языка R 14
1.3.2 Обзор ключевых библиотек 15
1.3.3 Примеры использования R в обработке данных 16
1.4 Программное обеспечение Glarus BI 17
1.4.1 Общая характеристика BI-системы 17
1.4.2 Основные функциональные возможности 17
1.4.3 Примеры использования Glarus BI для анализа данных 18
1.5 Сравнение возможностей R и Glarus BI 19
1.5.1 Где R удобнее 19
1.5.2 Где Glarus BI удобнее 19

1.5.3 Возможность совместного использования инструментов 20
2 ПРАКТИЧЕСКАЯ РЕАЛИЗАЦИЯ ИССЛЕДОВАНИЯ 21
2.1 Описание используемых данных 21
2.1.1 Источники данных 21
2.1.2 Структура и характеристики данных 21
2.1.3 Предварительная обработка данных 23
2.2 Исследовательский анализ данных 26
2.2.1 Визуализация распределений 26
2.2.2 Корреляционный анализ 31
2.3 Применение методов статистического анализа 35
2.3.1 Описательная статистика 35
2.3.2 Проверка гипотез 36
2.3.3 Регрессионный анализ 37
2.4 Машинное обучение в анализе данных 39
2.4.1 Классификация данных 39
2.5 Визуализация данных 41
2.5.1 Визуализация в R 41
2.5.2 Интерактивные дашборды в Glarus BI. 43
2.5.3 Сравнение методов визуализации. 46
3 АВТОМАТИЗАЦИЯ И ОТЧЁТНОСТЬ В АНАЛИЗЕ ДАННЫХ 47
3.1 Генерация отчетов в R 47
3.1.1 Обоснование необходимости автоматизации отчетов. 47
3.1.2 Использование RMarkdown для создания отчетов. 47
3.1.3 Экспорт отчетов в PDF, HTML, Word 49
3.2 Формирование интерактивных отчетов в Glarus BI 50

3.2.1 Различие между статичными и интерактивными отчетами. 50
3.2.2 Создание дашбордов в Glarus BI. 51
3.2.3 Экспорт отчетов в Glarus BI. 53
3.3 Сравнение инструментов R и Glarus BI 54
3.3.1 Анализ сильных и слабых сторон инструментов. 54
3.3.2 Возможности интеграции R и Glarus BI. 55
3.3.3 Применимость инструментов для различных типов задач. 55
ЗАКЛЮЧЕНИЕ 57
СПИСОК ИСТОЧНИКОВ 60
ПРИЛОЖЕНИЕ 63

ВВЕДЕНИЕ

В современных условиях стремительного развития цифровых технологий объёмы обрабатываемых данных в финансовой сфере постоянно увеличиваются. Особенно это касается операций с банковскими картами, которые стали неотъемлемой частью повседневной жизни. Однако вместе с удобством использования таких инструментов возрастает и количество мошеннических действий, направленных на незаконное получение денежных средств. Это делает задачу выявления мошенничества одной из наиболее актуальных в области анализа данных.

Объектом исследования в данной работе являются транзакции по кредитным картам, а предметом исследования — методы классификации данных, применяемые для выявления мошеннических операций.

Целью курсовой работы является разработка программы классификации данных на основе полносвязной нейронной сети прямого распространения для обнаружения мошеннических действий с кредитными картами.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Рассмотреть предметную область и особенности анализа транзакционных данных.
2. Изучить основные методы статистической обработки данных.
3. Провести обзор инструментов анализа данных, включая язык программирования R и систему Glarus BI.
4. Разработать модель классификации на основе нейронной сети.
5. Реализовать программное решение и оценить его эффективность.

Актуальность темы обусловлена необходимостью повышения уровня безопасности финансовых операций и снижением убытков, связанных с мошенничеством. Традиционные методы контроля зачастую оказываются недостаточно эффективными, особенно при обработке больших объёмов данных,

поэтому применение методов машинного обучения и нейронных сетей становится всё более востребованным.

В работе используются методы статистического анализа, машинного обучения и обработки данных. В частности, применяются методы описательной статистики, корреляционного анализа, классификации, а также алгоритмы обучения нейронных сетей.

1 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ СТАТИСТИЧЕСКОЙ ОБРАБОТКИ ДАННЫХ

1.1 Описание предметной области

1.1.1 Значимость анализа данных в рассматриваемой области

Анализ данных играет ключевую роль в системах обнаружения мошенничества. Это связано с тем, что объём транзакционной информации постоянно увеличивается, и ручная проверка операций становится невозможной. Использование статистических методов и алгоритмов машинного обучения позволяет автоматизировать процесс выявления мошеннических действий и существенно повысить его эффективность. [1]

Кроме того, современные подходы дают возможность обнаруживать неочевидные закономерности в поведении пользователей, что особенно важно при выявлении новых, ранее неизвестных схем мошенничества, анализ данных способствует не только снижению финансовых потерь банков, но и повышению уровня безопасности клиентов.

1.1.2 Основные типы данных

В задачах обнаружения мошенничества используются различные типы данных, каждый из которых играет свою роль в процессе анализа:

- числовые данные включают такие параметры, как сумма транзакции, баланс счёта, количество операций за определённый период времени. Эти данные позволяют оценивать количественные характеристики поведения пользователя;

- категориальные данные отражают качественные признаки, например тип торговой точки, категория товара, географическое расположение операции или способ проведения платежа. Они помогают учитывать контекст совершаемых транзакций;
- временные ряды представляют собой последовательность операций во времени. Их анализ позволяет выявлять аномальные изменения в поведении пользователя, например резкое увеличение частоты операций или проведение транзакций в необычное время. [2]

1.1.3 Ключевые задачи статистического анализа

Основными задачами статистического анализа в рассматриваемой области являются прогнозирование, выявление закономерностей и оптимизация процессов обработки данных.

Прогнозирование заключается в оценке вероятности того, что конкретная транзакция является мошеннической. Для этого используются различные модели классификации, включая нейронные сети.

Выявление закономерностей направлено на поиск скрытых зависимостей в данных, которые могут указывать на наличие мошеннической активности. Это позволяет формировать признаки, повышающие точность моделей.

Оптимизация процессов связана с улучшением качества работы системы обнаружения мошенничества. В частности, важной задачей является снижение количества ложных срабатываний, поскольку излишняя блокировка операций может негативно сказаться на пользователях. Рассмотренная предметная область требует применения комплексного подхода к анализу данных, включающего использование статистических методов и современных алгоритмов машинного обучения. Это обосновывает выбор полносвязной нейронной сети прямого распространения в качестве основного инструмента решения задачи классификации в рамках данной работы.

1.2 Основные методы статистической обработки данных

1.2.1 Описательная статистика

На первом этапе анализа данных применяется описательная статистика, позволяющая получить общее представление о наборе данных. К основным характеристикам относятся среднее значение, медиана, мода и дисперсия.

Среднее значение используется для оценки «центра» распределения данных, однако в задачах обнаружения мошенничества оно не всегда является показательным из-за наличия выбросов [3]. В таких случаях более устойчивой характеристикой выступает медиана. Мода, в свою очередь, позволяет определить наиболее часто встречающиеся значения признаков.

Дисперсия и стандартное отклонение характеризуют разброс данных и позволяют оценить степень их вариативности. Это особенно важно при анализе транзакций, так как резкие отклонения от нормального поведения пользователя могут свидетельствовать о мошенничестве.

1.2.2 Методы проверки гипотез

Для более глубокого анализа данных применяются методы проверки статистических гипотез. Они позволяют определить, являются ли наблюдаемые различия в данных значимыми или возникли случайно.

Одним из наиболее распространённых методов является t-тест, который используется для сравнения средних значений двух выборок. Например, его можно применять для сравнения характеристик обычных и подозрительных транзакций.

Дисперсионный анализ (ANOVA) используется в случаях, когда необходимо сравнить более двух групп данных. Это может быть полезно при анализе транзакций в разных категориях торговых точек.

Критерий хи-квадрат применяется для анализа категориальных данных и проверки зависимости между признаками [4]. Например, он может использоваться для определения связи между типом операции и вероятностью мошенничества.

1.2.3 Корреляционный анализ и регрессионное моделирование

Корреляционный анализ позволяет оценить степень взаимосвязи между различными признаками. Например, можно определить, существует ли зависимость между суммой транзакции и вероятностью её мошеннического характера. Однако корреляция не означает причинно-следственную связь, поэтому для более точного анализа применяются методы регрессионного моделирования. Линейная и логистическая регрессия позволяют строить модели зависимости целевой переменной от набора признаков. [5]

В задачах классификации, таких как выявление мошенничества, чаще используется логистическая регрессия, так как она позволяет оценивать вероятность принадлежности объекта к определённому классу. Несмотря на появление более сложных моделей, регрессия остаётся важным базовым инструментом анализа.

При обработке больших массивов транзакционных данных важным этапом является отбор наиболее информативных признаков, что позволяет снизить размерность модели и избежать переобучения. Для этого в банковском секторе и задачах кредитного скоринга активно применяются методы взаимной информации (Mutual Information) и ценности информации (Information Value).

Взаимная информация (Mutual Information, MI) — статистический метод, основанный на концепции энтропии Шеннона [6]. Он измеряет количество

информации, содержащейся в одной случайной переменной относительно другой. Главное преимущество MI заключается в способности улавливать любые типы зависимостей между признаками и целевой переменной, включая сложные нелинейные связи, которые невозможно обнаружить с помощью классического линейного корреляционного анализа Пирсона.

Ценность информации (Information Value, IV) — классический банковский стандарт для оценки предсказательной силы признаков по отношению к бинарной целевой переменной. Расчет IV базируется на показателе Weight of Evidence (WoE) и позволяет четко ранжировать факторы по группам: от слабых (IV < 0,02) до исключительно сильных (IV > 0,5). Применение IV критически важно в условиях сильного дисбаланса классов для отсева неинформативного шума.

1.2.4 Методы кластеризации и классификации

Особое место в анализе данных занимают методы кластеризации и классификации. Кластеризация относится к методам обучения без учителя и используется для группировки данных по сходству. В контексте данной работы она может применяться для выявления типичных моделей поведения пользователей без заранее заданных меток. Классификация, напротив, является методом обучения с учителем и предполагает наличие размеченных данных. Именно этот подход лежит в основе систем обнаружения мошенничества. К популярным методам классификации относятся логистическая регрессия, метод опорных векторов, деревья решений и нейронные сети.

В данной работе основной акцент делается на использовании полносвязной нейронной сети прямого распространения, которая способна учитывать сложные нелинейные зависимости между признаками и обеспечивает высокую точность классификации. [7]

1.2.5 Примеры практического применения статистических методов

На практике статистические методы широко применяются в различных областях, включая финансы, медицину, маркетинг и информационные технологии. В банковской сфере они используются для кредитного скоринга, оценки рисков и обнаружения мошеннических операций.

Например, описательная статистика применяется для предварительного анализа транзакционных данных и выявления выбросов. Методы проверки гипотез позволяют подтвердить значимость различий между группами операций. Корреляционный анализ используется для отбора наиболее информативных признаков, а методы классификации — для построения моделей, автоматически определяющих подозрительные транзакции.

В совокупности данные методы образуют основу для построения интеллектуальных систем анализа данных. Их использование позволяет повысить точность выявления мошенничества и снизить количество ошибок, что делает их неотъемлемой частью современных банковских систем.

1.3 Язык программирования R и его возможности для статистического анализа

1.3.1 Основные преимущества языка R

Одним из главных преимуществ языка R является его ориентированность на статистический анализ. В отличие от универсальных языков программирования, таких как Python или Java, R предоставляет готовые инструменты для выполнения сложных вычислений без необходимости реализации их «с нуля».

Также важным преимуществом является открытый исходный код и активное сообщество пользователей. Это приводит к постоянному развитию языка и появлению новых пакетов, расширяющих его функциональность.

Кроме того, R обладает мощными средствами визуализации данных, позволяющими строить графики различной сложности. Это особенно важно при анализе транзакционных данных, где необходимо наглядно выявлять аномалии и закономерности.

Ещё одной особенностью является удобная работа с таблицами и датафреймами, что упрощает обработку больших наборов данных. Благодаря этому язык R часто используется на этапе предварительного анализа и подготовки данных.

1.3.2 Обзор ключевых библиотек

Функциональность языка R во многом определяется используемыми библиотеками. Среди наиболее популярных можно выделить несколько ключевых пакетов.

Пакет tidyverse представляет собой набор инструментов для обработки и анализа данных, объединённых общей философией работы с данными. Он включает в себя несколько библиотек, каждая из которых выполняет определённую задачу.

Одной из таких библиотек является dplyr, предназначенная для обработки и преобразования данных. Она позволяет удобно фильтровать, сортировать и агрегировать данные, что особенно полезно при работе с транзакциями.

Для визуализации данных широко используется библиотека ggplot2, которая предоставляет гибкие средства построения графиков. С её помощью можно анализировать распределения признаков, выявлять выбросы и строить наглядные диаграммы.

Пакет caret применяется для построения и оценки моделей машинного обучения. Он содержит инструменты для обучения моделей, настройки гиперпараметров и оценки качества классификации.

Библиотека forecast используется для анализа временных рядов и построения прогнозов. Это может быть полезно при анализе последовательностей транзакций и выявлении аномального поведения во времени.

1.3.3 Примеры использования R в обработке данных

На практике язык R применяется на различных этапах анализа данных. В первую очередь он используется для загрузки и предварительной обработки данных, включая очистку, обработку пропущенных значений и преобразование признаков.

С помощью описательной статистики можно получить общее представление о данных, определить их структуру и выявить аномалии. Например, анализ распределения сумм транзакций позволяет обнаружить подозрительно крупные операции.

С использованием библиотек визуализации можно строить графики, отражающие поведение пользователей, что помогает выявлять нетипичные паттерны. R активно применяется для построения моделей машинного обучения [8]. С его помощью можно обучать классификаторы, оценивающие вероятность мошенничества для каждой транзакции. Несмотря на то, что в данной работе основная модель реализуется в виде нейронной сети, язык R может использоваться на этапе анализа данных и подготовки признаков.

Язык R является мощным инструментом для статистической обработки данных, обеспечивающим широкий набор возможностей для анализа, визуализации и моделирования. Его использование позволяет повысить качество исследования и обоснованность полученных результатов.

1.4 Программное обеспечение Glarus BI

1.4.1 Общая характеристика BI-системы

Glarus BI представляет собой систему бизнес-аналитики, ориентированную на обработку и анализ данных из различных источников [9]. Основной задачей подобных систем является преобразование «сырых» данных в удобную для восприятия информацию, которая может использоваться для принятия решений.

BI-системы, включая Glarus BI, обеспечивают интеграцию данных, их структурирование и последующий анализ. Они позволяют работать с большими объёмами информации без необходимости глубоких знаний в программировании, что делает их удобными для широкого круга пользователей.

Кроме того, подобные системы поддерживают интерактивное взаимодействие с данными, что даёт возможность быстро получать ответы на возникающие вопросы и проводить исследовательский анализ.

1.4.2 Основные функциональные возможности

Одной из ключевых возможностей Glarus BI является импорт данных из различных источников. Это могут быть базы данных, электронные таблицы или другие внешние системы. Возможность объединения данных из разных источников позволяет формировать единое информационное пространство для анализа.

Также важной функцией является визуализация данных. Glarus BI предоставляет инструменты для построения графиков, диаграмм и дашбордов, которые позволяют наглядно представить результаты анализа. Это особенно

полезно при работе с транзакционными данными, где важно быстро выявлять аномалии и отклонения.

Функции анализа данных включают в себя фильтрацию, агрегацию и группировку информации. Пользователь может задавать различные параметры и получать аналитические отчёты в интерактивном режиме. Это позволяет глубже изучать данные и находить скрытые закономерности.

1.4.3 Примеры использования Glarus BI для анализа данных

Glarus BI может использоваться для анализа транзакций с целью выявления мошеннических операций. Например, с его помощью можно построить дашборд, отображающий распределение транзакций по суммам, времени и географическому признаку. Это позволяет быстро обнаружить нетипичные операции.

Система может применяться для мониторинга активности пользователей. Анализируя частоту и последовательность транзакций, можно выявить аномальные паттерны поведения, которые могут свидетельствовать о мошенничестве.

Данная BI-система применяется для предварительного анализа данных перед их дальнейшей обработкой с помощью методов машинного обучения. В частности, он позволяет выявить выбросы, оценить структуру данных и определить наиболее значимые признаки.

Использование Glarus BI в сочетании с методами статистического анализа и машинного обучения позволяет повысить эффективность обработки данных и улучшить качество выявления мошеннических операций. [10]

1.5 Сравнение возможностей R и Glarus BI

1.5.1 Где R удобнее

Язык R обладает высокой гибкостью и предоставляет широкие возможности для проведения сложного статистического анализа. Он позволяет реализовывать практически любые методы обработки данных, включая построение математических моделей и применение алгоритмов машинного обучения.

Одним из главных преимуществ R является возможность работы со сложными моделями, такими как нейронные сети, что особенно важно в задачах классификации и прогнозирования. Кроме того, пользователь имеет полный контроль над процессом анализа, начиная от загрузки данных и заканчивая интерпретацией результатов.

R позволяет автоматизировать обработку данных и повторно использовать написанный код, что делает его удобным при проведении исследований и разработке программных решений. Однако стоит отметить, что для эффективной работы с этим языком требуются определённые навыки программирования.

1.5.2 Где Glarus BI удобнее

В отличие от R, система Glarus BI ориентирована на удобство использования и визуальное представление данных. Она не требует глубоких знаний программирования, что делает её доступной для более широкого круга пользователей.

Основным преимуществом Glarus BI является возможность создания интерактивных отчётов и дашбордов. Пользователь может в реальном времени изменять параметры анализа, фильтровать данные и получать наглядные

результаты. Это особенно удобно при презентации данных и принятии управленческих решений. Система обеспечивает быструю загрузку и обработку данных, а также их визуализацию без необходимости написания кода. Однако возможности Glarus BI в части реализации сложных моделей и нестандартных алгоритмов анализа ограничены по сравнению с языком R.

1.5.3 Возможность совместного использования инструментов

На практике наиболее эффективным является совместное использование R и Glarus BI. Каждый из инструментов может применяться на определённом этапе анализа данных, дополняя друг друга.

Язык R целесообразно использовать для предварительной обработки данных, проведения статистического анализа и построения моделей машинного обучения. В частности, он может применяться для разработки и обучения нейронной сети, предназначенной для классификации транзакций.

Glarus BI, в свою очередь, удобно использовать для визуализации результатов и представления данных в виде интерактивных отчётов. Это позволяет наглядно демонстрировать полученные результаты и облегчает их интерпретацию. Комбинированное использование данных инструментов позволяет объединить гибкость и мощность анализа языка R с удобством визуализации и простотой работы Glarus BI.

2 ПРАКТИЧЕСКАЯ РЕАЛИЗАЦИЯ ИССЛЕДОВАНИЯ

2.1 Описание используемых данных

2.1.1 Источники данных

Используемый в данной работе датасет, содержащий операции с банковскими картами пользователей из США, взят с платформы Kaggle [11]. Данные сгенерированы с помощью симулятора данных Sparkov Data Generation, созданного Брэндоном Харрисом. Данные создаются на основе статистических профилей пользователей, содержащихся в JSON-файлах, которые задают для каждой демографической группы распределения частоты, категорий и сумм транзакций, временные паттерны и вероятность поездок [12]. Такая симуляция имитирует реальное поведение людей, что делает синтетические транзакции статистически неотличимыми от настоящих, при этом полностью контролируемыми и масштабируемыми.

2.1.2 Структура и характеристики данных

В датасете содержится 1604294 строк, каждая из которых описывает транзакцию по двадцати двум параметрам. В них входят следующие характеристики:

- trans_date_trans_time — дата и время транзакции;
- cc_num — номер кредитной карты клиента;
- merchant — название торговой точки;

- category — категория торговой точки;
- amt — сумма транзакции;
- first — имя владельца кредитной карты;
- last — фамилия владельца кредитной карты;
- gender — пол владельца кредитной карты;
- street — улица адреса владельца кредитной карты;
- city — город владельца кредитной карты;
- state — штат владельца кредитной карты;
- zip — почтовый индекс владельца кредитной карты;
- lat — широта местоположения владельца кредитной карты;
- long — долгота местоположения владельца кредитной карты;
- city_pop — население города владельца кредитной карты;
- job — профессия владельца кредитной карты;
- dob — дата рождения владельца кредитной карты;
- trans_num — номер транзакции;
- unix_time — время транзакции в формате UNIX;
- merch_lat — широта местоположения торговой точки;
- merch_long — долгота местоположения торговой точки;
- is_fraud — флаг, указывающий на мошенничество, целевая переменная.

Из них 7 числовых, 4 категориальных поля и 2 столбца формата дата-время. Остальные столбцы содержат информацию в строковом формате. На Рисунке 2.1.1 показаны первые 10 строк исходного набора данных.

	trans_date_trans_time	cc_num	merchant	category	amt	first	last	gender	street	city	...	lat	long	city_pop	job	dob	trans_num	unix_time	merch_lat	merch_long	is_fraud
	<chr>	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	...	<chr>	<chr>	<int>	<chr>	<chr>	<chr>	<int>	<chr>	<chr>	<int>
1	2020-06-21 12:14:25	2.291164e+15	fraud_Kirlin and Sons	personal_care	2.86	Jeff	Elliott	M	351 Darlene Green	Columbia	...	33.9659	-80.9355	333497	Mechanical engineer	1968-03-19	2da90c7d74bd46a0caf3777415b3ebd3	1371816865	33.986391	-81.200714	0
2	2020-06-21 12:14:33	3.573030e+15	fraud_Sporer-Keebler	personal_care	29.84	Joanne	Williams	F	3638 Marsh Union	Altonah	...	40.3207	-110.436	302	Sales professional, IT	1990-01-17	324cc204407e99f51b0d6ca055005e7	1371816873	39.450497999999996	-109.960431	0
3	2020-06-21 12:14:53	3.598215e+15	fraud_Swaniawski, Nitzsche and Welch	health_fitness	41.28	Ashley	Lopez	F	9333 Valentine Point	Bellmore	...	40.6729	-73.5365	34496	Librarian, public	1970-10-21	c81755dbbbea9d5c77f094348a7579be	1371816893	40.49581	-74.196111	0
4	2020-06-21 12:15:15	3.591920e+15	fraud_Haley Group	misc_pos	60.05	Brian	Williams	M	32941 Krystal Mill Apt. 552	Titusville	...	28.5697	-80.8191	54767	Set designer	1987-07-25	2159175b9efe66dc301f149d3d5abf8c	1371816915	28.812397999999998	-80.883061	0
5	2020-06-21 12:15:17	3.526826e+15	fraud_Johnston-Casper	travel	3.19	Nathan	Massey	M	5783 Evan Roads Apt. 465	Falmouth	...	44.2529	-85.0170000000001	1126	Furniture designer	1955-07-06	57ff021bd3f328f8738bb535c302a31b	1371816917	44.959148	-85.884734	0
6	2020-06-21 12:15:37	3.040768e+13	fraud_Daugherty LLC	kids_pets	19.55	Danielle	Evans	F	76752 David Lodge Apt. 064	Breesport	...	42.1939	-76.7361	520	Psychotherapist	1991-10-13	798db04aaceb4febd084f1a7c404da93	1371816937	41.747157	-77.584197	0
7	2020-06-21 12:15:44	2.131807e+14	fraud_Romaguera Ltd	health_fitness	133.93	Kayla	Sutton	F	010 Weaver Land	Carlotta	...	40.507	-123.9743	1139	Therapist, occupational	1951-01-15	17003d7ce534440eadb10c4750e020e5	1371816944	41.499458000000004	-124.888729	0
8	2020-06-21 12:15:50	3.589290e+15	fraud_Reichel LLC	personal_care	10.37	Paula	Estrada	F	350 Stacy Glens	Spencer	...	43.7557	-97.5936	343	Development worker, international aid	1972-03-05	8bea473af4f05fc6146ea55ace73e7ca2	1371816950	44.495498	-97.728453	0
9	2020-06-21 12:16:10	3.596357e+15	fraud_Goyette, Howell and Collier	shopping_pos	4.37	David	Everett	M	4138 David Fall	Morrisdale	...	41.0001	-78.2357	3688	Advice worker	1973-05-27	71a1da150d1ce510193d7622e08e784e	1371816970	41.546067	-78.120238	0
10	2020-06-21 12:16:11	3.546898e+15	fraud_Kilback Group	food_dining	66.54	Kayla	Obrien	F	7921 Robert Port Suite 343	Prairie Hill	...	31.6591	-96.8094	263	Barrister	1956-05-30	a7915132c7c4240996ba03a47f81e3bd	1371816971	31.782919	-96.366185	0

Рисунок 2.1.1 — Исходные данные

Как можно увидеть на Рисунке 2.1.1, некоторые данные имеют неправильный тип, это будет исправлено в следующем подразделе, затрагивающем предварительную обработку данных.

2.1.3 Предварительная обработка данных

Была проведена проверка на наличие пропусков и дубликатов в данных (Листинг 2.1.1).

Листинг 2.1.1 — Поиск дубликатов и пропусков

```
cat("Количество дубликатов: ", sum(duplicated(df)), "\n")
cat("Количество пропусков: ",sum(is.na(df)), "\n")
```

На Рисунке 2.1.2 видно, что в датасете отсутствуют пропуски и дубликаты, значит данный этап обработки завершён. На следующей стадии будет произведено преобразование типов данных признаков.

```
Количество дубликатов:  0
Количество пропусков:  0
```

Рисунок 2.1.2 — Количество дубликатов и пропусков в данных

После загрузки данных большинство столбцов имели строковый тип данных, они были изменены с помощью кода, представленного на Листинге 2.1.2.

Листинг 2.1.2 — Коррекция типов данных

```
library(psych)
df$amt <- as.numeric(df$amt)
df$lat <- as.numeric(df$lat)
df$long <- as.numeric(df$long)
df$city_pop <- as.numeric(df$city_pop)
df$merch_lat <- as.numeric(df$merch_lat)
df$merch_long <- as.numeric(df$merch_long)
df$long <- as.numeric(df$long)
df$trans_date_trans_time <- as.POSIXct(df$trans_date_trans_time)
df$dob <- as.Date(df$dob)
df$cc_num <- as.character(df$cc_num)
df$zip <- as.character(df$zip)
df$category <- as.factor(df$category)
df$state <- as.factor(df$state)
df$gender <- as.factor(df$gender)
df$is_fraud <- as.factor(df$is_fraud)
```

Далее были созданы новые признаке на основе уже существующих. Из столбца trans_date_trans_time были выделены столбцы с месяцем, днём недели, часом, в которые была совершена транзакция. С помощью столбцов trans_date_trans_time и dob был создан столбец с возрастом клиента на момент совершения транзакции. Используя столбцы long, lat, merch_lat и merch_long был сконструирован столбец, показывающий расстояние между владельцем карты и торговой точкой по формуле гаверсинуса:

$$d = 2r\,sin^{-1}\left(\sqrt{sin^2\frac{lat_2 - lat_1}{2} + cos\,lat_1 * cos\,lat_2 * sin^2\frac{long_2 - long_1}{2}}\right), (2.1)$$

где d — расстояние между двумя точками в километрах;

r — радиус Земли;

lat_1 — широта первой точки в радианах;

$long_1$ — долгота первой точки в радианах;

lat_2 — широта второй точки в радианах;

$long_2$ — долгота второй точки в радианах.

На Листинге 2.1.3 представлен код, который с помощью функций month, wday, houre, interval библиотеки lubridate, созданной для работы с датой и временем, были получены столбцы таблицы: month, day_of_week, hour, age, а также столбец purchase_dist, вычисляемый по формуле 2.1.

Листинг 2.1.3 — Создание дополнительных признаков

```
library(lubridate)

df$month <- month(df$trans_date_trans_time)
df$day_of_week <- wday(df$trans_date_trans_time, label = FALSE, week_start = 1)
df$hour <- hour(df$trans_date_trans_time)
df$age <- interval(df$dob, df$trans_date_trans_time) %/% years(1)
df$purchase_dist <- 2 * 6371.032 * asin(((sin((df$merch_lat * pi / 180 - df$lat
* pi / 180) / 2))^2 + cos(df$lat * pi / 180) * cos(df$merch_lat * pi / 180) *
(sin((df$merch_long * pi / 180 - df$long * pi / 180) / 2))^2)^0.5)
head(df, 10)
```

Первые четыре строки новых полей представлены на Рисунке 2.1.3.

age <dbl>	month <dbl>	day_of_week <dbl>	hour <int>	purchase_dist <dbl>
52	6	7	12	24.56159
30	6	7	12	104.92562
49	6	7	12	59.08037
32	6	7	12	27.69871

Рисунок 2.1.3 — Новые признаки

Была проверена корректность столбцов с возрастом, географическими координатами точек, суммами покупок и выведем результат (Листинг 2.1.4).

Листинг 2.1.4 — Проверка корректности признаков

```
cat("Ошибка в широте клиента: ", any(df$lat < -90 | df$lat > 90), "\n")
cat("Ошибка в широте торговой точке: ", any(df$merch_lat < -90 | df$merch_lat > 90), "\n")
cat("Ошибка в долготе клиента: ", any(df$long < -180 | df$long > 180), "\n")
cat("Ошибка в долготе торговой точке: ", any(df$merch_long < -180 | df$merch_long > 180), "\n")
cat("Ошибка в возрасте: ", any(df$age < 5 | df$age > 110), "\n")
cat("Ошибка в сумме: ", any(df$amt <= 0), "\n")
```

На Рисунке 2.1.3 видно, что данные этих столбцов корректны, ошибок не было выявлено.

```
Ошибка в широте клиента:  FALSE
Ошибка в широте торговой точке:  FALSE
Ошибка в долготе клиента:  FALSE
Ошибка в долготе торговой точке:  FALSE
Ошибка в возрасте:  FALSE
Ошибка в сумме:  FALSE
```

Рисунок 2.1.3 — Проверка данных на корректность

При обработке временных характеристик транзакций возникает ограничение стандартных метрических алгоритмов. При обычном линейном шкалировании от 0 до 23 часов значения 23:00 и 00:00 интерпретируются математическими моделями как максимально удаленные друг от друга точки, хотя в физической реальности они являются смежными.

Для устранения этого искажения и корректного отображения циклической природы времени реализовано тригонометрическое преобразование временного признака. Исходная переменная спроецирована на двухмерную окружность суток с помощью вычисления синуса и косинуса радиального угла по формулам:

$$hour_\sin = \sin\frac{2\pi \cdot hour}{24} \quad (2)$$

и

$$hour_\cos = \cos\frac{2\pi \cdot hour}{24}, \quad (3)$$

где $hour_sin$ — синусная компонента тригонометрического преобразования времени;

$hour_cos$ — косинусная компонента тригонометрического преобразования времени;

$hour$ — время совершения транзакции.

После выполнения всех этапов предобработки: исправления типов, создания дополнительных признаков и проверки корректности, итоговый датасет полностью подготовлен к проведению исследовательского анализа, целью которого является выявление визуальных и статистических закономерностей между признаками и целевой переменной.

2.2 Исследовательский анализ данных

2.2.1 Визуализация распределений

Для того, чтобы лучше понять специфику данных, с которым мы работаем, проведём EDA с использованием функционала языка R [13]. Основная цель визуализации на данном этапе — выявить различия между легальными и мошенническими транзакциями, которые могут быть неочевидны при простом сравнении средних значений. Графики плотности распределения сумм,

временные ряды доли мошеннических операций, столбчатые диаграммы по категориям и картографические тепловые карты позволяют сформировать первичные гипотезы о факторах, влияющих на риск мошенничества.

Был построен график ggplot распределения потраченных сумм (Листинг 2.2.1), используя логарифмическую шкалу для того, чтобы небольшие операции, к которым относится большинство транзакций, не слились в одну линию.

Листинг 2.2.1 — График распределения плотности сумм транзакций

```
ggplot(df, aes(x = amt, fill = factor(is_fraud))) +
  geom_density(alpha = 0.5) +
  scale_x_log10() +
  labs(title = "Плотность распределения сумм")
```

На Рисунке 2.2.1 голубым цветом показаны мошеннические списания, а красным – легальные операции. Можно увидеть, что большая часть легальных транзакций сосредоточена в промежутке до 200$, а мошеннические операции, среди которых встречаются и списания на сумму 5-50$, в основном превосходят 300$ и концентрируются в промежутке 900-1100$.

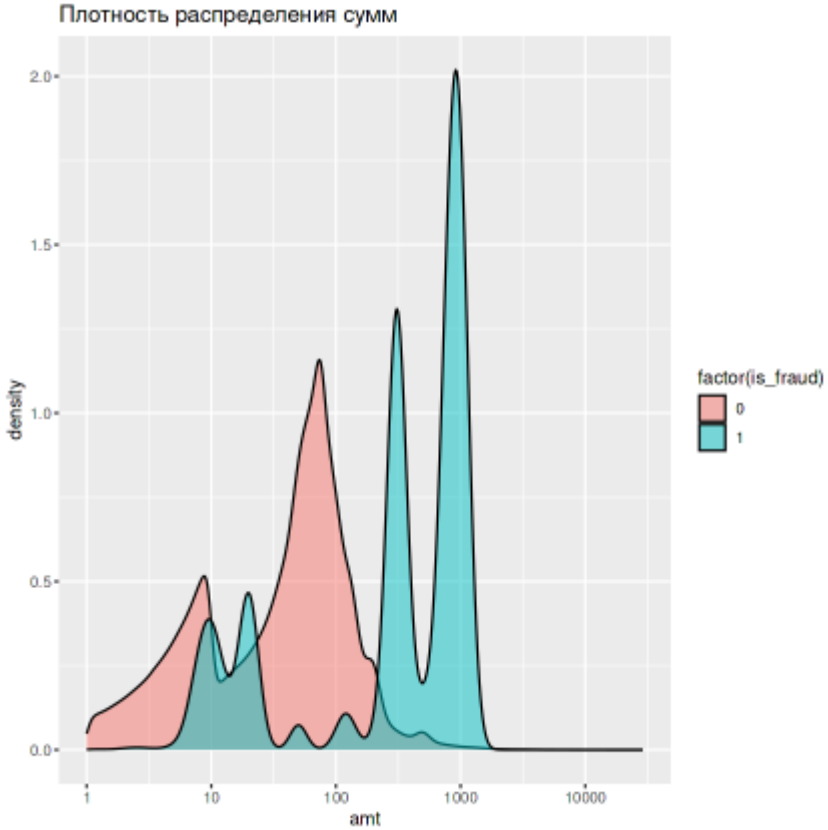


Рисунок 2.2.1 — Проверка данных на корректность

Далее был построен линейный график, который отражает временную зависимость мошенничества через долю нелегальных во всех операциях (Листинг 2.2.2).

Листинг 2.2.2 — График, отражающий долю мошеннических операций по часам

```
df %>%
  group_by(hour) %>%
  summarise(fraud_rate = mean(is_fraud)) %>%
  ggplot(aes(x = hour, y = fraud_rate)) +
  geom_line(color = "red", size = 1) +
  geom_point() +
  labs(title = "Доля мошеннических операций по часам")
```

Как видно на Рисунке 2.2.2, мошенники наиболее активны по ночам с 22:00 до 3:00, доля нелегальных операций в это время поднимается до 2,5%, тогда как в остальное время стабильно находится на уровне 0,1%.

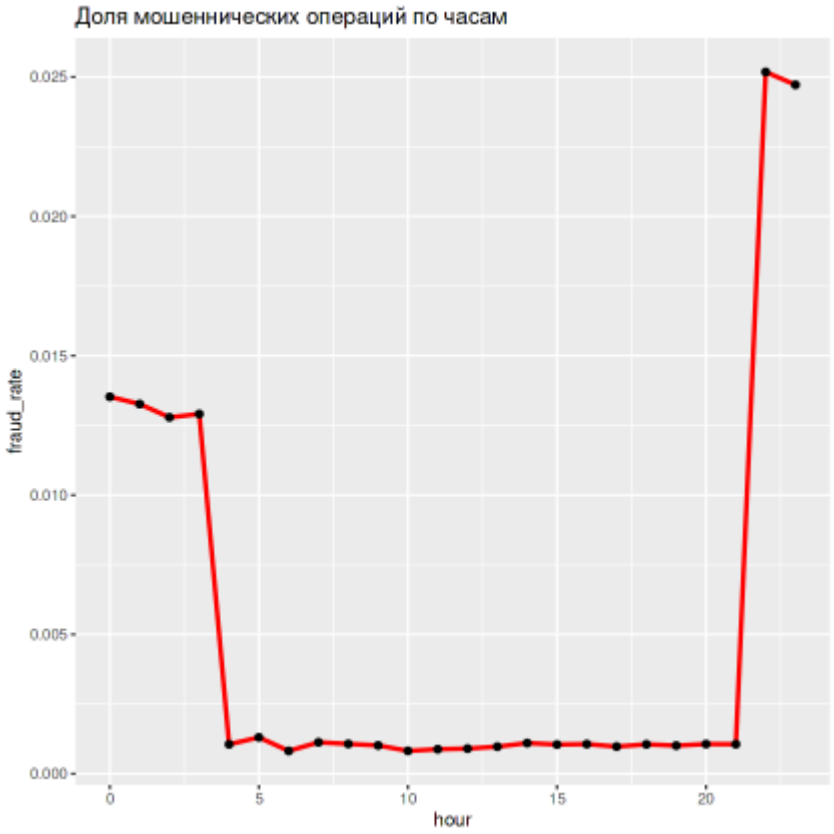


Рисунок 2.2.2 — Доля мошеннических операций по часам

Затем была построена вертикальная столбчатая диаграмма, на которой видны 10 категорий, в которых с наибольшей частотой совершаются кражи (Листинг 2.2.3). Для этого транзакции были сгруппированы по категориям и найдено среднее значение бинарного признака is_fraud.

Листинг 2.2.3 — График, отражающий долю мошеннических операций по категориям

```
df %>%
  group_by(category) %>%
  summarise(fraud_rate = mean(is_fraud)) %>%
  arrange(desc(fraud_rate)) %>%
  head(10) %>%
  ggplot(aes(x = reorder(category, fraud_rate), y = fraud_rate)) +
  geom_col(fill = "steelblue") +
  coord_flip() +
  labs(title = "Доля мошеннических операций по категориям")
```

Можно заметить, что чаще всего мошеннические операции совершаются при онлайн покупках, хотя примечательным является и то, что на 3 позиции стоит категория покупок в офлайн продуктовых магазинах, возможно это связано с кражей карт, данных и подписей с чеков или тратой средств с найденных физических карт (Рисунок 2.2.3). [14]

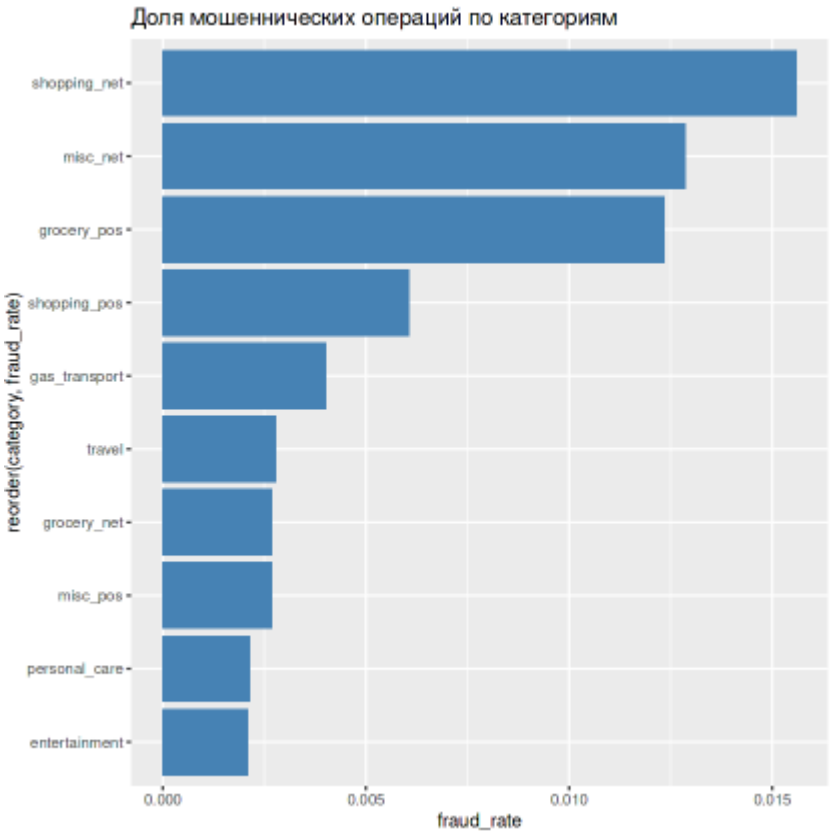


Рисунок 2.2.3 — Доля мошеннических операций по категориям

Был построен график распределения мошеннических и легальных транзакций по возрасту, представленный в виде ящика с усами (Листинг 2.2.4).

Листинг 2.2.4 — График, отражающий распределение возраста владельцев карт

```
ggplot(df, aes(x = factor(is_fraud), y = age, fill = factor(is_fraud))) +
  geom_boxplot() +
  labs(title = "Возраст жертв мошенничества")
```

На Рисунке 2.2.4 наглядно видно, что, в отличие от предыдущих графиков, на которых были видны чёткие различия между классами, боксплоты выглядят примерно одинаково, что говорит о том, что мошенники не нацелены на определённую возрастную категорию. Ящик, отражающий распределение для мошеннических операций лишь слегка смещён наверх.

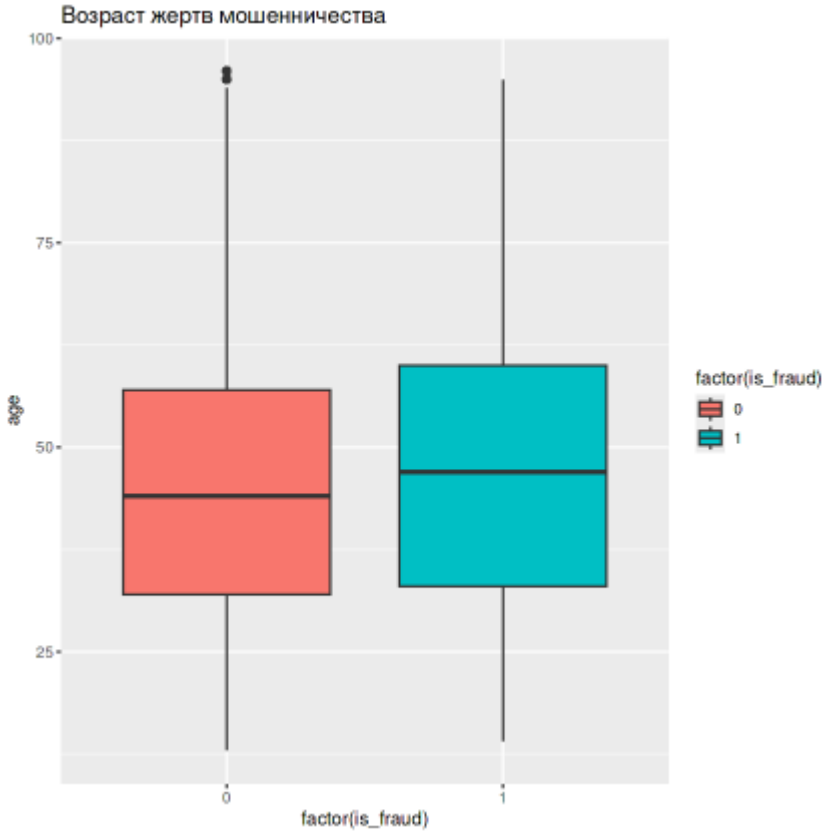


Рисунок 2.2.4 — Ящик с усами, отражающий признак age

В завершении этого раздела была построена тепловая карта, отражающая концентрацию нелегальных транзакций в США (Листинг 2.2.5). Жёлтым цветом показана низкая плотность, а красным – высокая.

Листинг 2.2.5 — График, отражающий плотность мошеннических операций на карте

```
usa <- st_as_sf(map("state", plot = FALSE, fill = TRUE))
ggplot() +
  geom_sf(data = usa, fill = "white", color = "grey") +
  stat_density_2d(data = fraud_data,
                  aes(x = merch_long, y = merch_lat, fill = ..level..),
                  geom = "polygon", alpha = 0.3) +
  scale_fill_gradient(low = "yellow", high = "red") +
  theme_minimal() +
  labs(title = "География мошенничества")
```

Можно заметить, что наибольшая плотность на восточном побережье, где находятся крупнейшие города США: Нью-Йорк, Филадельфия, Вашингтон и другие. Это можно объяснить большей плотностью населения и торговых точек, через которые можно проводить нелегальные операции (Рисунок 2.2.5).

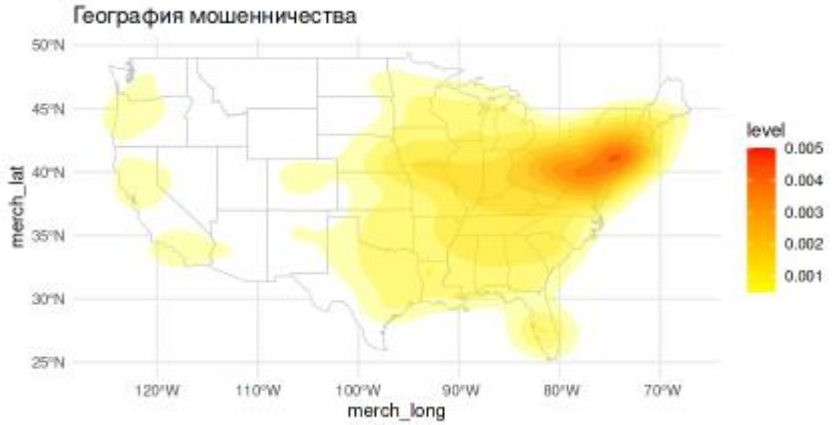


Рисунок 2.2.5 — Плотность мошеннических операций на карте

Описанные выше визуализации позволили сформировать первичные гипотезы о влиянии отдельных признаков на целевую переменную. Для подтверждения этих гипотез и выявления скрытых линейных зависимостей между переменными необходимо провести корреляционный анализ.

2.2.2 Корреляционный анализ

В данном разделе был проведён корреляционный анализ, для этого составлена матрица корреляции, включающая в себя предварительно скорректированные признаки: сумму транзакции в логарифмической шкале и изменённые типы данных признаков gender, state и category на числовой (Листинг 2.2.6). [15]

Листинг 2.2.6 — Матрица корреляции

```
cor_data <- df %>%
  mutate(
    gender_n = as.numeric(gender),
    state_n = as.numeric(state),
    cat_n = as.numeric(category),
    log_amt = log1p(amt)
  ) %>%
```

Продолжение Листинга 2.2.6

```
  select(is_fraud, log_amt, age, hour, city_pop, purchase_dist, gender_n,
state_n, cat_n)

M <- cor(cor_data, use = "complete.obs")

corrplot(M,
         method = "color",
         type = "upper",
         addCoef.col = "black",
         tl.col = "black",
         tl.srt = 45,
         diag = FALSE,
         sig.level = 0.05, insig = "blank"
)
```

На Рисунке 2.2.6 видно, что с целевым признаком is_fraud имеет слабую корреляцию только сумма транзакции, что является странным, так как графики говорили об обратном. Предположительно, зависимость между переменными не является линейной и метод Пирсона не может её уловить.

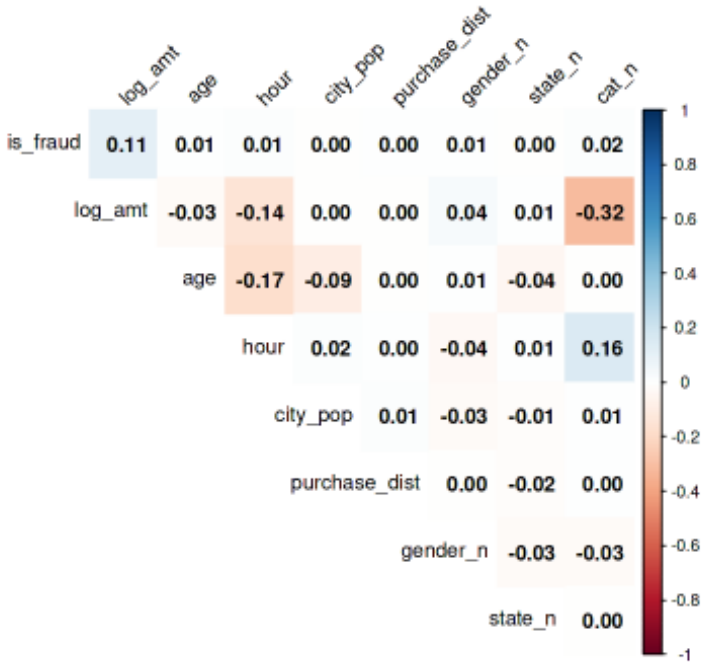


Рисунок 2.2.6 — Матрица корреляции

Поэтому были использованы методы: Mutual Information (MI), который позволил выявить любые типы зависимостей между признаками и фактом is_fraud, независимо от их формы, и Information Value (IV), который был выбран как классический банковский стандарт, он нужен для оценки силы связи.

Для реализации этих расчетов в R были использованы пакеты praznik и Information, так как они оптимизированы для обработки больших данных и работают значительно быстрее стандартных функций (Листинг 2.2.7).

Листинг 2.2.7 — Матрица корреляции

```
df <- df %>%
  mutate(state = as.character(state)) %>%
  mutate(state = ifelse(state %in% c("DE", "RI", "AK"), "Other", state)) %>%
  mutate(state = as.factor(state))
features <- c("merchant", "category", "amt", "city_pop", "age",
              "month",  "day_of_week",  "purchase_dist",  "gender",  "state",
"hour")
iv_analysis <- create_infotables(data = df[, c(features, "is_fraud")],
                                 y = "is_fraud",
                                 parallel = TRUE)
iv_table <- iv_analysis$Summary
df_mi <- df %>% select(all_of(features))

for(col in names(df_mi)) {
  if(is.numeric(df_mi[[col]])) {
    df_mi[[col]] <- as.integer(discretize(df_mi[[col]], nbins = 20)[,1])
  } else {
    df_mi[[col]] <- as.integer(as.factor(df_mi[[col]]))
  }
}
mi_scores <- miScores(X = df_mi, Y = as.integer(df$is_fraud))

mi_table <- data.frame(
  Variable = names(mi_scores),
  MI = as.numeric(mi_scores)
) %>% arrange(desc(MI))

final_importance <- iv_table %>%
  left_join(mi_table, by = "Variable") %>%
  arrange(desc(IV))

print(final_importance)
```

Для снижения размерности категориального признака state все штаты с частотой менее 0.1% объединены в категорию Other

Проведенный анализ позволил четко ранжировать признаки по их предсказательной способности, на основании таблицы, полученной на Рисунке 2.2.7.

	Variable	IV	MI
1	amt	3.3002934364	1.027518e-02
2	hour	1.7225413122	4.510389e-03
3	merchant	0.8324633481	2.068471e-03
4	category	0.7487471783	1.882160e-03
5	month	0.0953104676	2.508467e-04
6	age	0.0508740173	1.464918e-04
7	state	0.0375376470	9.782743e-05
8	day_of_week	0.0273657812	6.877930e-05
9	gender	0.0064967870	1.644473e-05
10	city_pop	0.0055295475	2.285070e-05
11	purchase_dist	0.0005140231	4.271892e-06

Рисунок 2.2.7 — Результат MI и IV

Абсолютным лидером стал признак суммы amt с высоким показателем $IV = 3{,}30$. Это подтверждает, что размер денежного списания является главным индикатором риска. Высокую значимость показали временной признак hour $IV = 1.7$ и категориальные признаки merchant и category с IV в диапазоне 0,7–0,8. Это доказывает, что мошенники нацелены на конкретные типы товаров и площадок. Среднее влияние оказали month и демографические факторы. Малополезным оказалось физическое расстояние до магазина, что позволило исключить его из дальнейшего построения модели.

Однако, несмотря на высокие математические значения метрик для признака merchant, принято решение исключить данную переменную из финального набора предикторов. Данный шаг обусловлен фактором high cardinality текстового признака merchant, содержащего тысячи уникальных наименований торгово-сервисных предприятий. Включение столь дробного категориального фактора в логистическую регрессию и полносвязную нейронную сеть привело бы к росту размерности матрицы признаков и неизбежному переобучению моделей.

На основе методов MI и IV определён набор наиболее информативных признаков, которые в дальнейшем лягут в основу модели классификации. Прежде чем переходить к машинному обучению, необходимо выполнить более детальное статистическое исследование этих признаков: расчёт описательных статистики в разрезе классов, проверку статистических гипотезы о значимости различий и построение регрессионной модели.

2.3 Применение методов статистического анализа

2.3.1 Описательная статистика

Следующим этапом данной работы является применение методов статистического анализа.

Для начала были рассчитаны основные описательные статистики данных для каждого из классов признака is_fraud, а именно среднее значение, стандартное отклонение, дисперсию и медиану. для некоторых признаков (Листинг 2.3.1).

Листинг 2.3.1 — Описательные статистики набора данных

```
desc_stats <- df %>%
  group_by(is_fraud) %>%
  summarise(
    n = n(),
    mean_amt = mean(amt),
    sd_amt = sd(amt),
    var_amt = var(amt),
    mean_dist = mean(purchase_dist, na.rm = TRUE),
    median_amt = median(amt)
  )
```

На Рисунке 2.3.1 наглядно видны различия между классами, которые наблюдались на графиках: огромное различие средних значений сумм списаний с карт между классами, схожесть средних расстояния от покупателя до торговой точки, что подтверждает информацию, которая была получена в предыдущем пункте.

```
# A tibble: 2 × 7
  is_fraud       n mean_amt sd_amt var_amt mean_dist median_amt
     <int>   <int>    <dbl>  <dbl>   <dbl>     <dbl>      <dbl>
1        0 1596143     67.6   153.  23492.      76.1       47.2
2        1    8151    530.    392. 153416.      76.2      385.
```

Рисунок 2.3.1 — Описательные статистики

На основе визуального анализа и описательных статистик будут сформулированы несколько гипотез о характере различий между легальными и

мошенническими транзакциями и проведена их проверка с помощью статистических критериев.

2.3.2 Проверка гипотез

Сначала, было проверено, является ли огромный разрыв в средних чеках статистически значимым или это просто случайное совпадение в данных. Для этого использовался t-теста Уэлча. Были сформулированы 2 гипотезы:

1. H_0: Средние суммы легальных и мошеннических транзакций одинаковы.
2. H_1: Средние суммы существенно различаются.

Код, с помощью которого проводилось тестирование представлен на Листинге 2.3.2.

Листинг 2.3.2 — t-тест

```
t_test_result <- t.test(amt ~ is_fraud, data = df)
print(t_test_result)
```

Проведенный t-тест Уэлча показал крайне низкое значение p-уровня значимости (Рисунок 2.3.2). Это позволяет отвергнуть нулевую гипотезу. Таким образом, сумма транзакции является надежным и математически обоснованным признаком для классификации мошенничества.

```
        Welch Two Sample t-test

data:  amt by is_fraud
t = -106.53, df = 8162.8, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -470.8748 -453.8595
sample estimates:
mean in group 0 mean in group 1
       67.62292       529.99007
```

Рисунок 2.3.2 — t-тест

Затем было проверено, распределяется ли мошенничество по категориям товаров случайно или есть четкая зависимость. Для этого использован тест Хи-квадрат Пирсона. Были сформулированы 2 гипотезы:

1. H_0: Категория покупки и мошенничество не связаны.
2. H_1: Между категорией и фродом существует статистически значимая связь.

Код, с помощью которого проводилось тестирование представлен на Листинге 2.3.3.

Листинг 2.3.3 — Хи-квадраты

```
contingency_table <- table(df$category, df$is_fraud)
chi_sq_result <- chisq.test(contingency_table)
print(chi_sq_result)
```

Результаты теста Хи-квадрат (Рисунок 2.3.3) позволяют полностью отвергнуть нулевую гипотезу, значит мошенничество напрямую зависит от категории покупки. Это обосновывает использование признака category как одного из важнейших параметров при построении прогнозных моделей.

```
        Pearson's Chi-squared test

data:  contingency_table
X-squared = 7092.7, df = 13, p-value < 2.2e-16
```

Рисунок 2.3.3 — Хи-квадраты

Проверка гипотез подтвердила статистическую значимость различий между классами по сумме транзакции и категории покупки. Однако для количественной оценки силы влияния этих факторов на вероятность мошенничества необходимо провести регрессионный анализ.

2.3.3 Регрессионный анализ

Для количественной оценки влияния выбранных факторов на вероятность мошенничества была применена логистическая регрессия. В спецификацию

модели включены предикторы, продемонстрировавшие наибольшую информативность по результатам предварительного анализа: стандартизированный логарифм суммы log_amt, категория торгово-сервисного предприятия category, непрерывный масштабированный возраст клиента age, а также тригонометрические компоненты суточного цикла hour_sin и hour_cos, рассчитанные по формулам 2 и 3. Учитывая сильный дисбаланс классов, для обучения использовались веса, обратно пропорциональные частоте классов. Это позволило скорректировать смещение модели в сторону мажоритарного класса. Реализация модели представлена в Листинге 2.3.4.

Листинг 2.3.4 — Логистическая регрессия

```
model_data <- df %>%
  mutate(
    log_amt = log1p(amt),
    hour_sin = sin(2 * pi * hour / 24),
    hour_cos = cos(2 * pi * hour / 24),
    age = as.numeric(scale(age)),
    log_amt = as.numeric(scale(log_amt))
  ) %>%
  select(is_fraud, log_amt, category, hour_sin, hour_cos, age)
weight_0 <- 1 / (table(model_data$is_fraud)[1] / nrow(model_data))
weight_1 <- 1 / (table(model_data$is_fraud)[2] / nrow(model_data))
weights <- ifelse(model_data$is_fraud == 1, weight_1, weight_0)
logit_model <- glm(is_fraud ~ log_amt + category + hour_sin + hour_cos + age,
                   data = model_data,
                   weights = weights,
                   family = "binomial")
summary(logit_model)
exp(coef(logit_model))
```

Регрессионный анализ позволил получить конкретную математическую формулу для оценки риска (Рисунок 2.3.4).

```
Call:
glm(formula = is_fraud ~ log_amt + category + hour_sin + hour_cos +
    age, family = "binomial", data = model_data, weights = weights)

Coefficients:
                      Estimate Std. Error  z value Pr(>|z|)
(Intercept)           -2.885980   0.007850 -367.620  < 2e-16 ***
log_amt                1.119426   0.001787  626.311  < 2e-16 ***
categoryfood_dining    0.415489   0.010247   40.549  < 2e-16 ***
categorygas_transport  2.212165   0.009265  238.777  < 2e-16 ***
categorygrocery_net    1.826569   0.011521  158.540  < 2e-16 ***
categorygrocery_pos    1.570614   0.008695  180.627  < 2e-16 ***
categoryhealth_fitness 0.840003   0.010441   80.455  < 2e-16 ***
categoryhome          -0.063698   0.009772   -6.518 7.11e-11 ***
categorykids_pets      1.061602   0.009514  111.577  < 2e-16 ***
categorymisc_net       1.442629   0.010021  143.959  < 2e-16 ***
categorymisc_pos       1.795259   0.010358  173.321  < 2e-16 ***
categorypersonal_care  1.264775   0.009806  128.974  < 2e-16 ***
categoryshopping_net   1.535376   0.009090  168.912  < 2e-16 ***
categoryshopping_pos   0.943873   0.009376  100.670  < 2e-16 ***
categorytravel         2.453507   0.012126  202.333  < 2e-16 ***
hour_sin              -0.397508   0.003595 -110.562  < 2e-16 ***
hour_cos               1.733827   0.002639  656.897  < 2e-16 ***
age                    0.060759   0.001578   38.492  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 4448047  on 1604293  degrees of freedom
Residual deviance: 2496516  on 1604276  degrees of freedom
AIC: 2491562

Number of Fisher Scoring iterations: 8
```

(Intercept): 0.0558001016566964 **log_amt:** 3.06309494505946 **categoryfood_dining:** 1.51511208305492 **categorygas_transport:** 9.13547289016698 **categorygrocery_net:** 6.21253236668402 **categorygrocery_pos:** 4.80960053730908 **categoryhealth_fitness:** 2.31637405461632 **categoryhome:** 0.938288557825394 **categorykids_pets:** 2.89099775770578 **categorymisc_net:** 4.23180596471724 **categorymisc_pos:** 6.02103166940287 **categorypersonal_care:** 3.54229653784789 **categoryshopping_net:** 4.64307111750472 **categoryshopping_pos:** 2.56991573133308 **categorytravel:** 11.6290641259172 **hour_sin:** 0.671992813194953 **hour_cos:** 5.66228311763142 **age:** 1.06264246761043

Рисунок 2.3.4 — Результаты регрессионного анализа

Было доказано, что мошенничество не случайно: оно концентрируется в крупных суммах и онлайн-категориях в ночное время. Полученные коэффициенты могут быть использованы для создания системы автоматической блокировки подозрительных транзакций.

Статистические методы подтвердили значимость отобранных признаков. Но для достижения максимальной точности классификации и учёта скрытых нелинейных паттернов перейдём к построению модели на основе нейронной сети.

2.4 Машинное обучение в анализе данных

2.4.1 Классификация данных

Для поиска наиболее сложных и скрытых зависимостей, которые могут быть упущены классической регрессией, была разработана полносвязная

нейронная сеть прямого распространения. Архитектура модели включает несколько скрытых слоев с функцией активации ReLU и слои Dropout для защиты от переобучения на таком огромном массиве данных [16]. Чтобы нейросеть не игнорировала редкие случаи мошенничества, обучение проводилось с использованием весов классов, что позволило добиться максимально точного разделения операций на легальные и мошеннические (Листинг 2.4.1).

Листинг 2.4.1 — Полносвязная нейронная сеть прямого распространения

```
model_data <- df %>%
  mutate(
    log_amt = log1p(amt),
    hour_sin = sin(2 * pi * hour / 24),
    hour_cos = cos(2 * pi * hour / 24),
    age = as.numeric(scale(age)),
    log_amt = as.numeric(scale(log_amt))
  ) %>%
  select(is_fraud, log_amt, category, hour_sin, hour_cos, age)
features_matrix <- model.matrix(is_fraud ~ . -1, data = model_data)
target <- as.matrix(model_data$is_fraud)

set.seed(42)
index <- sample(1:nrow(features_matrix), 0.8 * nrow(features_matrix))
x_train <- features_matrix[index, ]
y_train <- target[index, ]
x_test  <- features_matrix[-index, ]
y_test  <- target[-index, ]

model <- keras_model_sequential() %>%
  layer_dense(units = 64, activation = 'relu', input_shape = ncol(x_train)) %>%
  layer_dropout(rate = 0.2) %>%
  layer_dense(units = 32, activation = 'relu') %>%
  layer_dropout(rate = 0.2) %>%
  layer_dense(units = 1, activation = 'sigmoid')
model %>% compile(
  loss = 'binary_crossentropy',
  optimizer = optimizer_adam(learning_rate = 0.001),
  metrics = c('accuracy', 'AUC')
)

counts <- table(y_train)
class_weights <- list("0" = 1, "1" = as.numeric(counts["0"] / counts["1"]))

history <- model %>% fit(
  x_train, y_train,
  epochs = 20,
  batch_size = 512,
  validation_split = 0.2,
  class_weight = class_weights,
  verbose = 1
)
results <- model %>% evaluate(x_test, y_test)
print(results)
```

Построенная полносвязная нейросеть продемонстрировала исключительную эффективность с показателем AUC = 0,997. Несмотря на то, что общая точность составила 97,6%, это является следствием применения весовых коэффициентов для борьбы с дисбалансом (Рисунок 2.4.1).

```
      loss   accuracy        auc
0.06205927 0.97652549 0.99721658
```

Рисунок 2.5.1 — Динамика обучения

Модель успешно идентифицирует сложные, нелинейные паттерны мошенничества, значительно превосходя базовые статистические методы. [17]

Построенная нейронная сеть показала высокие метрики качества. Для наглядной демонстрации её эффективности проведём визуализацию результатов: динамики обучения, ROC-кривой и матрице ошибок.

2.5 Визуализация данных

2.5.1 Визуализация в R

В данном разделе была проведена визуализация результатов работы построенной модели [18]. Для начала, был построен график динамики обучения нейронной сети по эпохам (Рисунок 2.5.1).

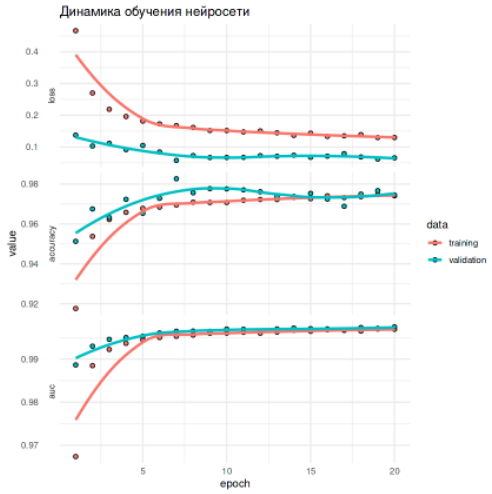


Рисунок 2.5.1 — Динамика обучения

Анализ графиков динамики обучения подтверждает высокое качество построенной модели. Сходимость кривых обучения и валидации по всем метрикам: Loss, Accuracy, AUC, свидетельствует об отсутствии эффекта переобучения. Модель демонстрирует высокую скорость обучения, достигая оптимальных показателей уже к 5-й эпохе, и сохраняет стабильность на протяжении всего цикла, что гарантирует надежность её предсказаний на реальных данных.

Далее была построена ROC-кривая, представленная на Рисунке 2.5.2.

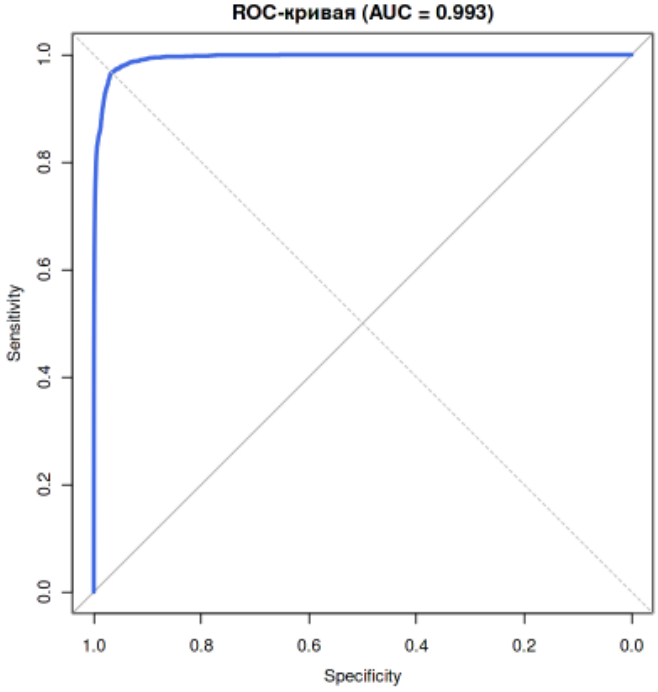


Рисунок 2.5.2 — ROC-кривая

Построенная ROC-кривая и значение AUC подтверждают исключительное качество классификации. Высокое значение AUC означает, что модель с высокой вероятностью присвоит более высокий риск мошенничества случайно выбранной фрод-транзакции, чем случайно выбранной легальной. Данный результат значительно превосходит показатели классических статистических методов и доказывает эффективность применения нейронных сетей для выявления сложных схем мошенничества.

На Рисунке 2.5.3. представлена матрица ошибок, построенная с помощью функции table().

	Predicted	
Actual	0	1
0	310944	8213
1	30	1672

Рисунок 2.5.3 — Матрица ошибок

Анализ матрицы ошибок подтверждает высокую практическую ценность нейросети. Модель успешно выявила 98,2% мошеннических операций, что критически важно для минимизации прямых убытков. Относительно высокий уровень ложноположительных срабатываний около 2,6% является допустимым компромиссом в задачах Fraud Detection, так как цена пропуска реальной кражи значительно превышает стоимость дополнительной верификации честной транзакции

2.5.2 Интерактивные дашборды в Glarus BI.

В данном разделе данные были визуализированы посредством построения графиков в среде Glarus BI [19]. Для выявления пространственных закономерностей и географической концентрации транзакционного мошенничества было проведено геокодирование данных, результаты которого для США представлены на Рисунке 2.5.4.

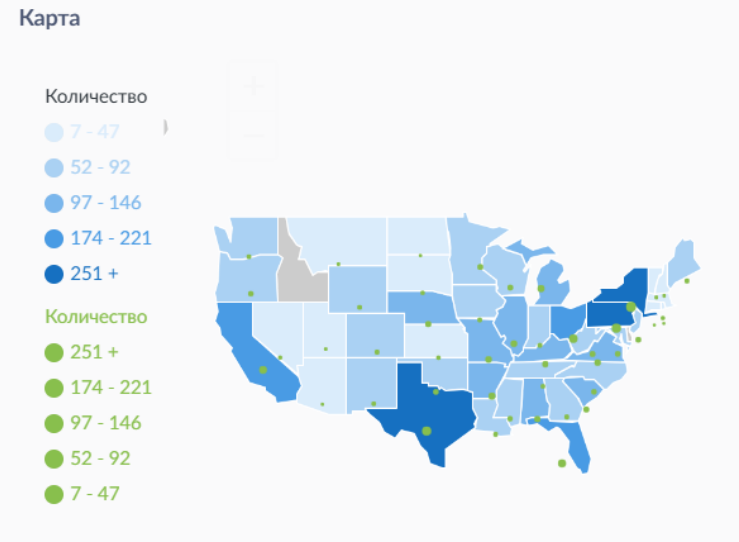


Рисунок 2.5.4 — Расположение жертв мошенников на карте

Важным аспектом социально-демографического анализа является оценка уязвимости различных групп населения к действиям злоумышленников. На Рисунке 2.5.5 представлено распределение зафиксированных случаев транзакционного фрода в зависимости от пола пострадавших клиентов, созданное с помощью инструмента «Пирог» в Glarus BI.

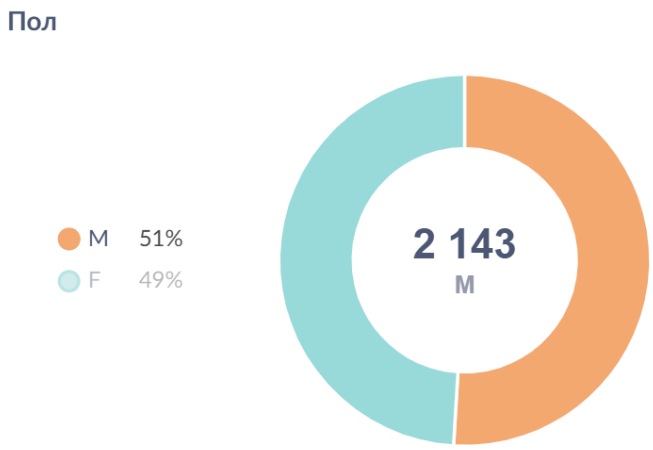


Рисунок 2.5.5 — Соотношение пострадавших мужского и женского полов

Для определения наиболее уязвимых категорий торговых точек был проведён анализ структуры операций в разрезе категорий расходов. Результаты распределения инцидентов представлены на Рисунке 2.5.6. Визуализация реализована с помощью древовидной карты, где площадь каждого прямоугольника пропорциональна количеству совершенных мошеннических

операций в конкретной категории, что позволяет наглядно оценить иерархию и масштаб рисков.



Рисунок 2.5.6 — Количество мошеннических операций по категориям

Для исследования временных паттернов поведения злоумышленников было изучено распределение фрод-транзакций по часам суток (Рисунок 2.5.7).

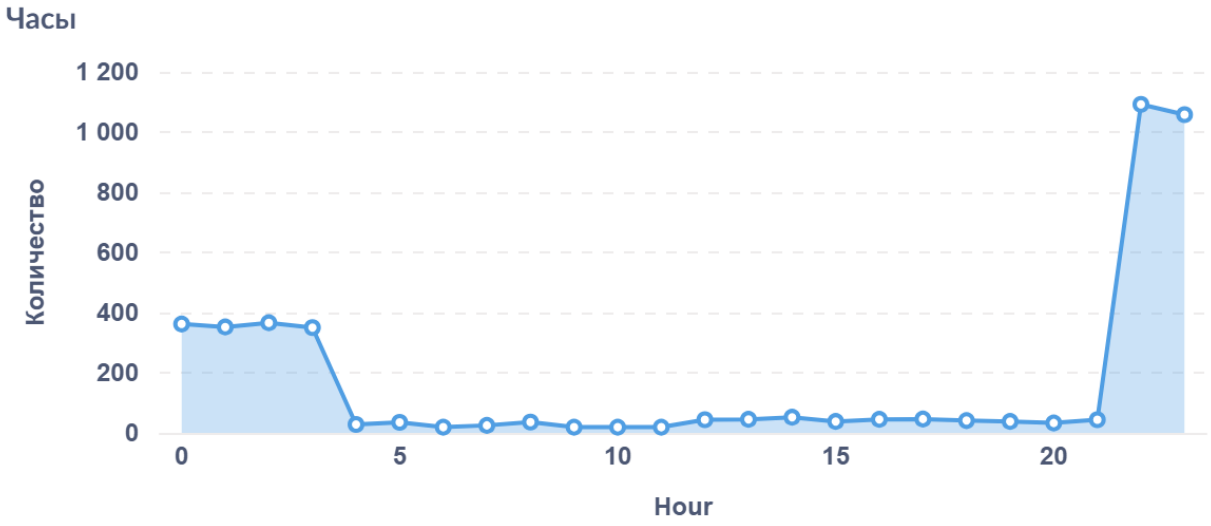


Рисунок 2.5.7 — Количество мошеннических операций в течении дня

Данный график был построен в виде линейной диаграммы с областями. При анализе временного профиля была обнаружена ярко выраженная аномальную активность в ночные часы, как и на графике, построенном при использовании языка R.

Заметно, что основной пик мошеннических операций придходится на интервал с 22:00 до 03:00, когда количество инцидентов резко возрастает и достигает максимальных значений.

В данном разделе было успешно реализовано построение аналитических графиков двумя альтернативными способами: с помощью программного кода в среде R и посредством визуального no-code интерфейса платформы Glarus BI. Далее будет представлен сравнительный анализ, использованных инструментов.

2.5.3 Сравнение методов визуализации.

Использование R для визуализации оказалось эффективным благодаря пакету ggplot2, который позволяет выстраивать графики по слоям и полностью контролировать каждую деталь. На огромных массивах в 1,6 млн строк инструменты среды подсвечивают скрытые закономерности, превращая цифровой хаос в наглядные и понятные аналитические образы. Такой подход делает процесс исследования не только быстрым, но и невероятно информативным, позволяя создавать графику профессионального уровня без лишних усилий.

Glarus BI предоставляет удобную технику drag-and-drop, но может обрабатывать только файлы с расширением .xlsx и .xls, а значит имеет ограничение на 2^{20} строк в таблице. Также в нём имеется ограничение по размеру передаваемого файла в 100 Мб. и отсутствует функционал для вертикального объединения отдельных файлов в один внутри программы, поэтому в данном исследовании не было возможности визуализировать весь объём данных, что существенно повлияло на результат.

3 АВТОМАТИЗАЦИЯ И ОТЧЁТНОСТЬ В АНАЛИЗЕ ДАННЫХ

3.1 Генерация отчетов в R

3.1.1 Обоснование необходимости автоматизации отчетов.

В современных условиях работы с большими массивами данных, такими как рассмотренный в данной работе набор из более чем 1,6 млн транзакций, ручная подготовка аналитических материалов становится неэффективной и экономически нецелесообразной. Ручное копирование графиков в текстовые документы, пересчёт статистических метрик и обновление таблиц требуют значительных временных затрат, повышают риск человеческой ошибки и затрудняют воспроизводимость результатов. Кроме того, в задачах обнаружения мошенничества данные и модели постоянно обновляются, что делает статичные, созданные вручную отчёты быстро теряющими актуальность.

Автоматизация генерации отчётов решает эти проблемы, обеспечивая воспроизводимость, скорость и масштабируемость, снижение риска ошибок, интеграцию в рабочий процесс.

3.1.2 Использование RMarkdown для создания отчетов.

Основным инструментом автоматизации документации в экосистеме R является пакет rmarkdown, работающий в связке с движком knitr. RMarkdown позволяет объединять в едином документе повествовательный текст, результаты выполнения R-кода, графики, таблицы, математические формулы и

динамические параметры [20]. Архитектура RMarkdown-документа строится на трёх компонентах: YAML-заголовке, текстовое содержание и код-чанках.

Для демонстрации возможности создания документации в RStudio был написан код для создания RMarkdown документа [21]. Результат выполнения скрипта представлен на Рисунке 3.1.1.

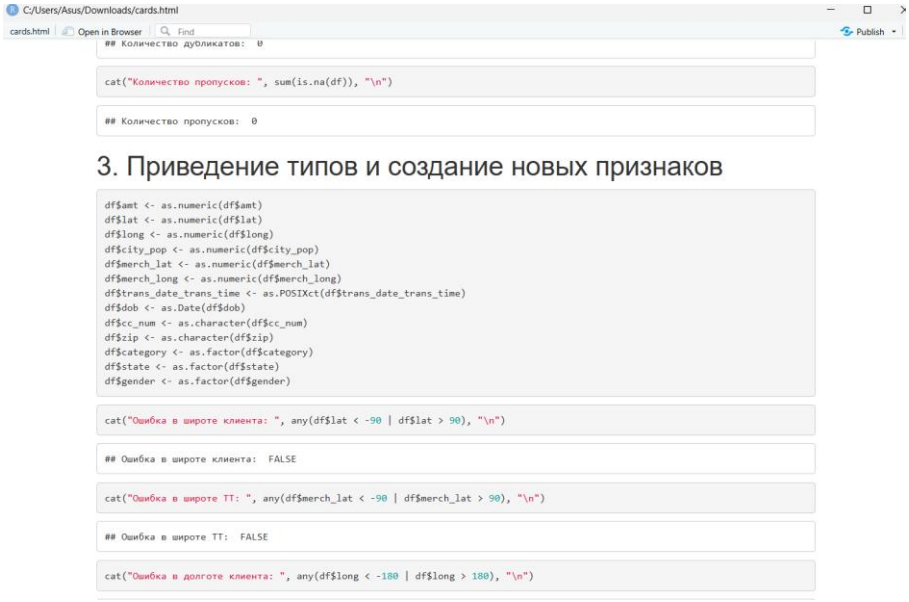


Рисунок 3.1.1 — Отчёт R Markdown

В результате получился полноценный отчёт с оглавлением и подсветкой синтаксиса. В отчёт попали все визуализации: плотности распределения сумм, графики доли мошенничества по часам и категориям, карты с кластеризацией точек, тепловые карты корреляции, результаты t-теста и хи-квадрат, а также итоги логистической регрессии и нейронной сети.

Важным преимуществом RMarkdown является поддержка динамического контента через params. Например, можно задать дату отчёта, порог вероятности мошенничества или путь к файлу с данными, что позволяет генерировать серию отчётов под разные сценарии без изменения исходного шаблона. Для задач, рассмотренных в данной работе, это означает возможность быстрого формирования документов с актуальными метриками AUC, матрицами ошибок и распределениями признаков по часам или категориям.

3.1.3 Экспорт отчетов в PDF, HTML, Word.

R Markdown позволяет преобразовать один и тот же исходный .Rmd файл в три основных формата: HTML, PDF и Word, причём для переключения между ними достаточно изменить одну строку в YAML-заголовке (Рисунок 3.1.2).

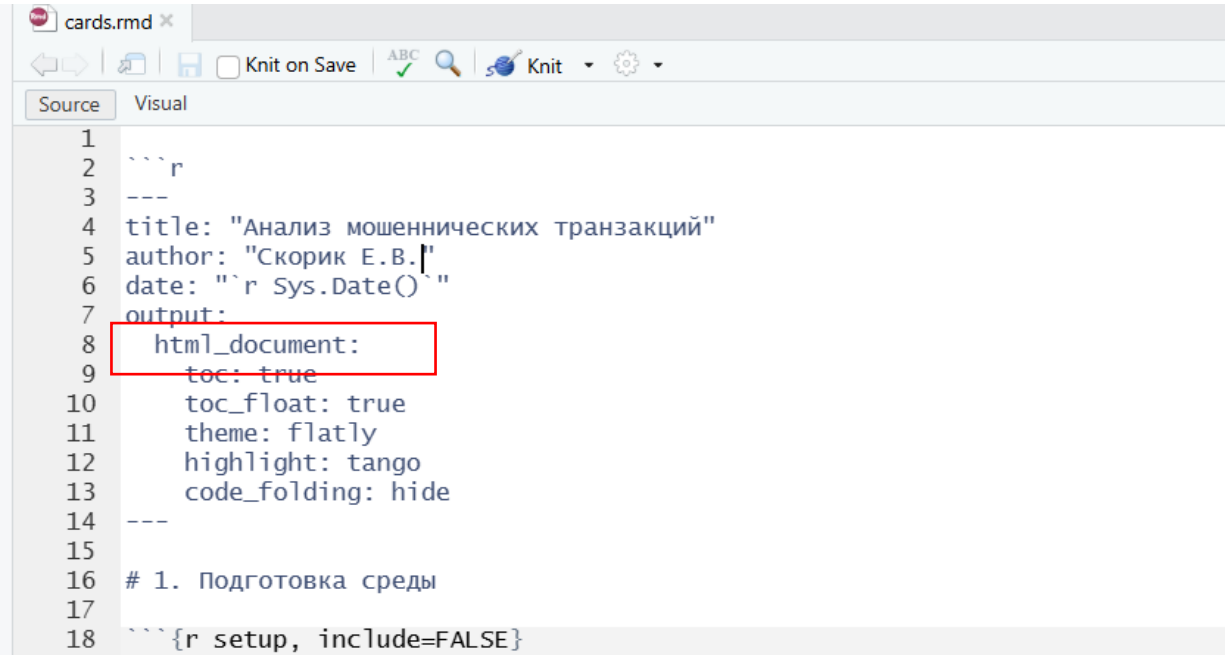


Рисунок 3.1.2 — Изменение расширения отчёта

HTML-формат наиболее универсален и подходит для интерактивных отчётов: в нём сохраняются динамические элементы, такие как карты Leaflet, всплывающие подсказки, сворачиваемые блоки кода и интерактивные таблицы. Такой отчёт легко открывается в любом браузере, его можно разместить на веб-сервере или отправить коллегам без дополнительных программ. HTML поддерживает разные темы оформления и автоматическое плавающее оглавление, что делает его удобным для презентаций и внутреннего использования.

PDF-формат — стандарт для академических статей, официальных отчётов и печатных документов. Он фиксирует точное расположение графиков, таблиц и текста, обеспечивая одинаковый вид на любом устройстве. Для генерации PDF из R Markdown требуется установленная система LaTeX; при первой попытке скомпилировать PDF RStudio обычно предлагает установить необходимые

компоненты. В PDF можно добавлять номера страниц, колонтитулы, оглавление и даже внедрять шрифты. При желании можно сохранить промежуточный LaTeX-код и доработать его вручную для тонкой настройки вёрстки.

Word — формат, востребованный в корпоративной среде, когда отчёт нужно передать руководителю или заказчику, привыкшему редактировать документы в Microsoft Word. R Markdown генерирует полностью готовый файл .docx с базовым оформлением: заголовками, таблицами, рисунками и списками. После этого документ можно открыть в Word и дополнительно отформатировать , не теряя при этом результатов анализа. Единственное ограничение: интерактивные элементы в Word не работают — они превращаются в статические изображения. Тем не менее для большинства стандартных отчётов с графиками ggplot2 этого вполне достаточно.

3.2 Формирование интерактивных отчетов в Glarus BI

3.2.1 Различие между статичными и интерактивными отчетами.

Статичные отчёты, сгенерированные в RMarkdown или PDF представляют собой фиксированный снимок данных на определённый момент времени. Они неизменяемы после экспорта и не позволяют пользователю самостоятельно изменять параметры анализа без повторного запуска скриптов. Такой формат оптимален для аудита, фиксации результатов обучения модели, подготовки нормативных документов или отправки выводов руководству, требующему чётких, верифицируемых данных.

Интерактивные отчёты, напротив, предоставляют пользователю возможность самостоятельно исследовать данные: применять фильтры, изменять уровень детализации, переключать типы визуализаций и получать ответы на вопросы в реальном времени без участия аналитика. В контексте мониторинга

мошеннических операций это позволяет сотрудникам службы безопасности быстро проверять подозрительные кластеры транзакций, анализировать активность по регионам или категориям и оперативно реагировать на инциденты. Выбор между инструментами зависит от цели: RMarkdown подходит для глубокого технического анализа и документирования, тогда как Glarus BI эффективен для оперативного контроля и визуального взаимодействия с данными. [22]

3.2.2 Создание дашбордов в Glarus BI.

В рамках практической реализации системы мониторинга транзакционной активности был разработан и настроен интерактивный аналитический дашборд в среде Glarus BI, представленный на Рисунке 3.2.1.

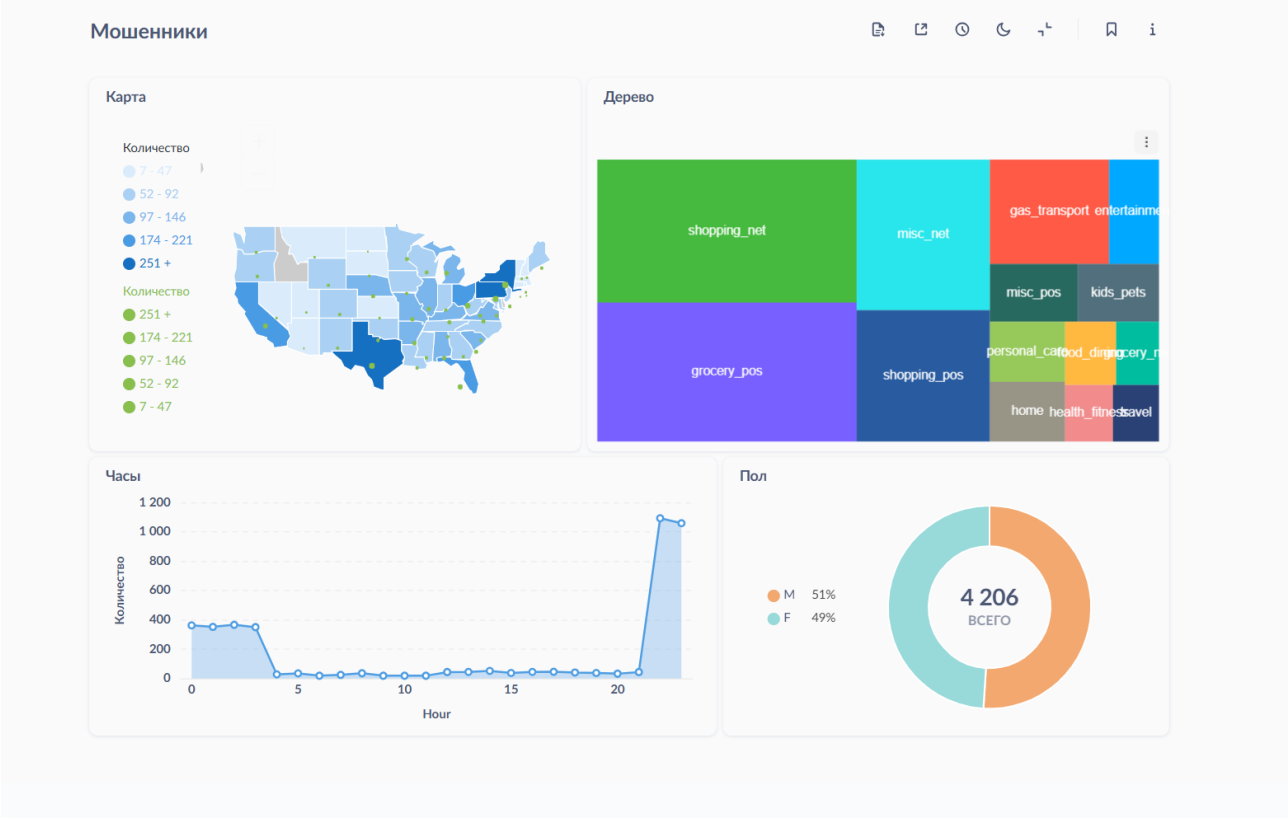


Рисунок 3.2.1 — Дашборд в Glarus BI

Архитектура созданного дашборда включает в себя четыре взаимосвязанных аналитических виджета:

1. Расположение жертв мошенников на карте. В левой верхней части панели размещена картограмма со встроенной точечной пузырьковой диаграммой. Этот виджет настроен на отображение плотности мошенничества по штатам. Цветовая шкала градиента используется для визуализации абсолютного количества инцидентов, а цветовая легенда интервалов позволяет мгновенно локализовать ключевые очаги угроз на карте.
2. Количество мошеннических операций по категориям. В правой верхней части дашборда построена древовидная карта для анализа структуры расходов. Каждому сектору торгово-сервисных предприятий присвоен отдельный цветовой маркер, а площадь прямоугольников пропорциональна числу фрод-операций. Таким образом, наглядно выделены доминирующие категории на общем фоне менее рискованных транзакций.
3. Количество мошеннических операций в течении дня. В левой нижней части панели сформирована линейная диаграмма с областями, отражающая динамику фрода по часам суток. С помощью этого виджета продемонстрирован резкий аномальный всплеск активности в ночном интервале, что служит важным аргументом для настройки правил фильтрации.
4. Распределение пострадавших от мошенничества по полу. В правой нижней части дашборда размещена кольцевая диаграмма с выводом общего числа зафиксированных мошеннических транзакций. На этот график выведено процентное соотношение пострадавших, что позволяет в реальном времени контролировать гендерный баланс выборки.

Платформа Glarus BI позволяет не только создавать интерактивные дашборды, но и экспортировать или выгружать исходные данные для внешнего анализа.

3.2.3 Экспорт отчетов в Glarus BI.

Несмотря на ориентацию на онлайн-взаимодействие, Glarus BI поддерживает экспорт аналитических панелей в статичные форматы для распространения среди заинтересованных сторон. Доступны опции, представленные на Рисунке 3.2.2.

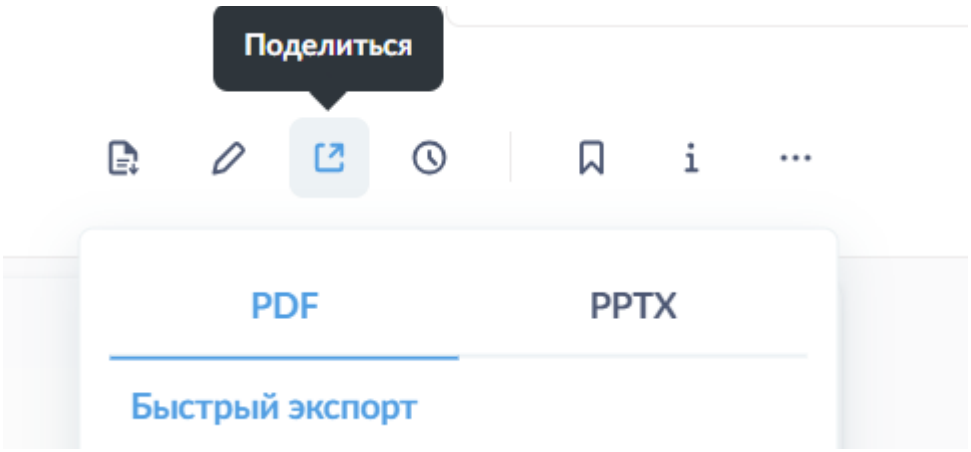


Рисунок 3.2.2 — Варианты экспорта дашборда в Glarus BI

Они включают в себя:

- экспорт в PDF: формирует точную копию дашборда с текущими применёнными фильтрами. Удобно для ежемесячных отчётов, презентаций на совещаниях или архивирования состояний системы;
- экспорт в PNG/JPEG: используется для вставки отдельных графиков в презентации, технические задания или внешние отчёты;
- публикация по ссылке: позволяет предоставить доступ к интерактивному дашборду через защищённую веб-ссылку с настройкой прав (только просмотр или возможность фильтрации).

Стоит отметить, что в отличие от RMarkdown, где экспорт является частью единого воспроизводимого конвейера, экспорт в Glarus BI чаще носит ситуативный характер и зависит от текущих фильтров, выбранных пользователем. Тем не менее, это обеспечивает гибкость в представлении данных для разных уровней управления.

3.3 Сравнение инструментов R и Glarus BI

3.3.1 Анализ сильных и слабых сторон инструментов.

При проведении сравнительного анализа инструментов для обработки и визуализации данных необходимо учитывать как функциональные возможности, так и практические ограничения каждой платформы. Язык программирования R демонстрирует высокую эффективность на всех этапах аналитического конвейера благодаря гибкости обработки данных, возможности работы с файлами произвольного формата и объёма, что критически важно при анализе транзакционных данных, превышающих 1,6 млн записей [23]. Полнота статистического инструментария, поддержка сложных методов машинного обучения и возможность автоматизации отчётности через пакет rmarkdown делают R предпочтительным выбором для исследовательского анализа и разработки моделей.

Платформа Glarus BI ориентирована на интуитивное визуальное взаимодействие с данными. Её интерфейс технологии drag-and-drop позволяет быстро создавать эстетически привлекательные визуализации без написания кода, что обеспечивает наглядность результатов для презентационных целей. Однако при практическом применении в рамках данной работы были выявлены существенные ограничения, сужающие область применимости Glarus BI для задач исследовательского анализа данных. Система поддерживает загрузку данных исключительно в форматах .xlsx и .xls, что исключает прямую работу с широко распространёнными в аналитике форматами CSV или JSON. Максимальный размер загружаемого файла ограничен 100 МБ, а количество строк — 2^{10}, что делает невозможным полную загрузку исходного датасета данной работы без существенной агрегации и потери детализации. Кроме того, платформа не предоставляет инструментов для вертикального или горизонтального слияния нескольких файлов внутри интерфейса, а отсутствие

поддержки пользовательских статистических тестов и кастомных преобразований данных существенно затрудняет проведение глубокого EDA.

3.3.2 Возможности интеграции R и Glarus BI.

Учитывая комплементарный характер сильных сторон рассматриваемых инструментов, оптимальным подходом является построение гибридного аналитического конвейера, в котором каждый инструмент применяется на соответствующем этапе. На этапе предобработки и моделирования загрузка сырых данных, очистка, создание признаков, проведение статистического анализа и обучение моделей машинного обучения выполняются в среде R с использованием пакетов tidyverse, caret, keras. Результаты анализа, такие как агрегированные метрики, скоринговые баллы и таблицы с выводами, экспортируются в формат .xlsx, совместимый с Glarus BI, с учётом ограничений на объём данных. На завершающем этапе подготовленные данные загружаются в Glarus BI для построения интерактивных дашбордов, предназначенных для демонстрации руководству или оперативного мониторинга.

Важно отметить, что такая интеграция требует дополнительной автоматизации процесса экспорта и импорта, например, через скрипты планировщика задач, что частично нивелирует преимущество Glarus BI в простоте использования. Тем не менее, при корректной настройке конвейера возможно сочетание вычислительной мощи R и наглядности Glarus BI, что позволяет создать эффективную систему поддержки принятия решений.

3.3.3 Применимость инструментов для различных типов задач.

Выбор инструмента должен определяться конкретными целями проекта, характеристиками данных и квалификацией команды. Для исследовательского

анализа данных, предобработки и очистки, а также построения и валидации моделей машинного обучения язык R является безальтернативным выбором благодаря поддержке сложных статистических тестов, возможности работы с большими данными и гибкости преобразований [24]. Автоматизация технической отчётности также эффективно реализуется в связке R и RMarkdown за счёт воспроизводимости, поддержки динамических параметров и экспорта в несколько форматов.

В свою очередь, Glarus BI целесообразно применять для задач оперативного мониторинга, бизнес-презентаций и визуализации агрегированных метрик для не технической аудитории, где интуитивный интерфейс, интерактивные фильтры и быстрое создание дашбордов обеспечивают существенное преимущество. В контексте задачи обнаружения мошеннических операций с кредитными картами, рассмотренной в данной работе, наиболее эффективным является комбинированный подход: R используется как основной инструмент для анализа, моделирования и генерации технических отчётов, тогда как Glarus BI применяется выборочно — для визуализации финальных, предварительно агрегированных результатов, предназначенных для демонстрации заинтересованным сторонам.

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсовой работы была достигнута поставленная цель — разработана система обнаружения мошеннических операций с банковскими картами на основе методов машинного обучения и статистического анализа транзакционных данных. В качестве основного классификатора была реализована полносвязная нейронная сеть прямого распространения, обученная на датасете, содержащем более 1,6 млн записей.

Для достижения цели были решены следующие задачи:

1. Проведён анализ предметной области и выявлены ключевые особенности транзакционных данных, включая сильный дисбаланс классов, наличие временных, географических и категориальных признаков, а также необходимость автоматизации процесса выявления фрода.
2. Изучены основные методы статистической обработки данны: описательная статистика, проверка гипотез, корреляционный анализ, методы отбора признаков Mutual Information и Information Value. Эти методы позволили выявить наиболее информативные признаки и подтвердить статистическую значимость их влияния на целевой признак.
3. Выполнен обзор и сравнение инструментов анализа данных: языка программирования R и BI-системы Glarus BI. Показано, что R обладает максимальной гибкостью для сложного статистического моделирования и работы с большими объёмами данных, тогда как Glarus BI предоставляет удобный интерфейс для интерактивной визуализации и оперативного мониторинга, однако имеет существенные ограничения по объёму и форматам импортируемых данных.
4. Разработана и обучена модель классификации, представленная в виде полносвязной нейронной сети с двумя скрытыми слоями (64 и 32

нейрона), функцией активации ReLU, слоями Dropout для защиты от переобучения и сигмоидным выходным слоем. Обучение проводилось с применением весов классов для компенсации дисбаланса выборки.

5. Реализовано программное решение и оценена его эффективность. Нейросеть продемонстрировала следующие метрики:
   - auc = 0,997 — исключительная способность разделять классы;
   - accuracy = 97,6%;
   - recall = 98,2% — выявлено 1672 из 1702 мошеннических операций в тестовой выборке;
   - ложноположительные срабатывания составили около 2,6%, что является допустимым компромиссом в задачах fraud-детекции.
6. Сравнительный анализ инструментов визуализации и отчётности показал, что связка R и RMarkdown оптимальна для автоматизации генерации технических отчётов с воспроизводимыми результатами, а Glarus BI эффективна для создания интерактивных дашбордов, предназначенных для бизнес-пользователей. Выявленные ограничения Glarus BI не позволяют использовать её для полноценного анализа исходного датасета без предварительной агрегации, что подтверждает необходимость комбинированного подхода.

Практическая значимость работы заключается в обосновании и реализации гибридной схемы анализа: на первом этапе средствами R выполняются загрузка, очистка, создание признаков, статистическое тестирование и обучение нейросетевой модели; на втором этапе агрегированные результаты экспортируются в Glarus BI для построения наглядных дашбордов, предназначенных для оперативного мониторинга. Такой подход позволяет сочетать вычислительную мощность языка R с удобством интерактивной визуализации, что повышает эффективность систем обнаружения мошенничества и снижает финансовые потери от противоправных действий.

В дальнейшем планируется провести сравнительный анализ разработанной нейронной сети с другими моделями машинного обучения, таких как случайный лес, градиентный бустинг, SVM, выполнить поиск оптимальных гиперпараметров с использованием байесовской оптимизации, внедрить методы интерпретируемого ИИ для объяснения решений модели.

СПИСОК ИСТОЧНИКОВ

1. Авдошин С. М., Песоцкая Е. Ю. Информационные системы обнаружения мошенничества (Антифрод): учебное пособие. — М.: Изд. дом Высшей школы экономики, 2011. — 184 с.
2. Травкин А. В. Выявление мошенничества в банковских транзакциях. Доступ: https://synthesis.frccsc.ru/synthesis/student/BigData/master-thesis/2017%20Травкин.pdf (дата обращения: 09.06.2026).
3. Анализ данных: учебник для вузов / под редакцией В.С. Мхитаряна. — М.: Издательство Юрайт, 2026. — 448 с. — (Высшее образование). — ISBN 978-5-534-19964-2.
4. Сергеев А. П., Арапов С. Ю., Буторова А. С. Основы статистической обработки данных в прикладных исследованиях: учебное пособие. — Екатеринбург: Изд-во Уральского университета, 2024. — 140 с.
5. Pohar M., Blas M., Turk S. Comparison of Logistic Regression and Linear Discriminant Analysis: A Simulation Study // Metodološki zvezki. — 2004. — Vol. 1, No. 1. — P. 143-161.
6. Peng H., Long F., Ding C. Feature Selection Based on Mutual Information: Criteria of Max-Dependency, Max-Relevance, and Min-Redundancy // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2005. — Vol. 27, no. 8. — P. 1226–1238.
7. Лобач А. О. Классификация искусственных нейронных сетей на основе структуры входных данных: табличные, временные ряды, графы и геопространственные данные // Вестник науки. — 2026. — № 5 (98). — Т. 1.
8. Кабаков Р. И. R в действии. Анализ и визуализация данных на языке R / Пер. с англ. Е. Н. Гижбицкой. — М.: ДМК Пресс, 2022. — 584 с.
9. Glarus BI. Доступ: https://russianbi.ru/vendors/detail.php?ID=872 (дата обращения: 09.06.2026).

10. Муштук С. Российские BI-системы: обзор и сравнение популярных решений после ухода Power BI. Доступ: https://bi-data.ru/blog/2025/06/13/российские-bi-системы-обзор-и-сравнение/ (дата обращения: 09.06.2026).
11. Kartik2112. Credit Card Fraud Detection. Доступ: https://www.kaggle.com/datasets/kartik2112/fraud-detection (дата обращения: 09.06.2026).
12. Harris B. Sparkov Data Generation: synthetic financial transaction simulator.
Доступ: https://github.com/namebrandon/Sparkov_Data_Generation (дата обращения: 09.06.2026).
13. The R Project for Statistical Computing. Доступ: https://www.r-project.org/ (дата обращения: 09.06.2026).
14. Ларионова С. Л. Механизмы противодействия мошенничеству в системах онлайн предоставления финансовых услуг. Доступ: http://elib.fa.ru/art2023/bv373.pdf (дата обращения: 09.06.2026).
15. Корреляционный анализ. Доступ: https://nweb42.com/books/r-lang/korrelyatsionnyy-analiz/ (дата обращения: 09.06.2026).
16. He J., Li L., Xu J., Zheng C. ReLU Deep Neural Networks and Linear Finite Elements // Journal of Computational Mathematics. — 2020. — Vol. 38, No. 3. — P. 502-527. — DOI: 10.4208/jcm.1901-m2018-0160.
17. Pimpalkar A. P., Somkunwar R. K., Chinchalkar S. P., Katakdound K. M., Bhide A. S., Patil Y. M. Parallelized Louvain-Based Community Detection and AntiBenford Subgraph Mining for Financial Fraud Detection in Transaction Networks // Informatica. — 2025. — Vol. 49, No. 4. — DOI: 10.31449/inf.v498i4.8298.
18. Wickham H., Grolemund G. R for Data Science: Import, Tidy, Transform, Visualize, and Model Data. — 2nd ed. — Sebastopol: O'Reilly Media, 2023. — 576 p. — ISBN 978-1-492-09740-2.

19. Glarus BI : документация. Версия 0.52. Доступ: https://glarus-bi.ru/docs/v0.52/ (дата обращения: 09.06.2026).
20. Xie Y., Allaire J. J., Grolemund G. RMarkdown: The Definitive Guide. — Boca Raton: Chapman and Hall/CRC, 2018. — ISBN 978-1-138-35933-2.
21. Листинг RMarkdown. Credit_card_fraud_detection. Доступ: https://github.com/veskel0-0/Credit_card_fraud_detection (дата обращения: 09.06.2026).
22. Glarus BI. Доступ: https://www.decosystems.ru/uslugi/glarus-bi/ (дата обращения: 10.06.2026).
23. Сравнение программ для анализа данных: R vs Power BI vs Python. Доступ: https://www.megaputer.ru (дата обращения: 10.06.2026).
24. ReportRmd: Streamlined statistical reporting in Rmarkdown environments. Доступ: https://cran.r-project.org/package=reportRmd (дата обращения: 10.06.2026).

ПРИЛОЖЕНИЕ

МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»

РТУ МИРЭА
Институт информационных технологий (ИИТ)
Кафедра прикладной математики (ПМ)
09.03.03 Прикладная информатика

КУРСОВАЯ РАБОТА
по дисциплине «Языки программирования для статистической обработки данных»

Тема: «Разработка программы классификации данных на базе полносвязной нейронной сети прямого распространения в целях выявления мошеннических действий с кредитными картами»

ФИО студента: Скорик Елизавета Витальевна
Группа: ИНБО-20-24
Руководитель курсовой работы: ст. преподаватель Трушин С.М.

Москва 2026 г.

1

Рисунок 1 — Первый слайд презентации

1.А. Введение

Актуальность

В условиях стремительного роста цифровых технологий объёмы транзакций по банковским картам постоянно увеличиваются. Однако вместе с удобством безналичных расчётов растёт и число мошеннических действий, направленных на хищение средств. Традиционные методы контроля, такие как простые правила или пороговые значения, часто оказываются недостаточно эффективными при обработке больших массивов данных. Именно поэтому сегодня возникает потребность в интеллектуальных методах анализа, способных автоматически выявлять подозрительные операции.



Объект и предмет исследования

- Объектом исследования выступают транзакции по кредитным картам
- Предметом исследования являются методы классификации данных, используемые для обнаружения мошеннических операций.

2

Рисунок 2 — Второй слайд презентации

1.Б. Введение

Цель работы

Разработать программу классификации данных на основе полносвязной нейронной сети прямого распространения, предназначенной для выявления мошеннических действий с кредитными картами.

Задачи

Для достижения этой цели необходимо решить следующие задачи:

- рассмотреть предметную область и особенности анализа транзакционных данных;
- изучить основные методы статистической обработки данных;
- провести обзор инструментов анализа данных, включая язык R и систему Glarus BI;
- разработать модель классификации на основе нейронной сети;
- реализовать программное решение и оценить его эффективность.

3

Рисунок 3 — Третий слайд презентации

1.В. Введение

Методы

- Описательная статистика (среднее, медиана, дисперсия)
- Проверка статистических гипотез (t-тест, хи-квадрат)
- Отбор признаков: Mutual Information (MI) и Information Value (IV)
- Логистическая регрессия
- Полносвязная нейронная сеть прямого распространения (с весами классов для борьбы с дисбалансом)



Ожидаемый результат

В итоге должна быть создана программа, способная с достаточной точностью выявлять мошеннические транзакции, что позволит повысить уровень безопасности финансовых операций и снизить убытки от мошенничества.

4

Рисунок 4 — Четвёртый слайд презентации

2.А. Источник данных

- Источник: Kaggle, симулятор Sparkov Data Generation
- 1 604 294 транзакции (пользователи из США)
- 22 исходных поля
- Целевая переменная: is_fraud (0 – легальная, 1 – мошенническая)
- Сильный дисбаланс классов (~0,5% мошеннических)

	trans_date_trans_time	cc_num	merchant	category	amt	first	last	gender	street	city	lat	long	city_pop	job	dob	trans_num	unix_time	merch_lat	merch_long	is_fraud
	<chr>	<dbl>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<chr>	<int>	<chr>	<chr>	<chr>	<int>	<chr>	<chr>	<int>
1	2020-06-21 12:14:25	2.291164e+15	fraud_Kirlin and Sons	personal_care	2.86	Jeff	Elliott	M	351 Darlene Green	Columbia	33.9659	-80.9355	333497	Mechanical engineer	1968-03-19	2da90c7d74bd46a0caf3777415b3ebd3	1371816865	33.986391	-81.200714	0
2	2020-06-21 12:14:33	3.573030e+15	fraud_Sporer-Keebler	personal_care	29.84	Joanne	Williams	F	3639 Marsh Union	Altonah	40.3207	-110.436	302	Sales professional, IT	1990-01-17	324cc204407e99f51b0d6ca0055005e7	1371816873	39.450497999999996	-109.960431	0
3	2020-06-21 12:14:53	3.598215e+15	fraud_Swaniawski, Nitzsche and Welch	health_fitness	41.28	Ashley	Lopez	F	9333 Valentine Point	Bellmore	40.6729	-73.5365	34496	Librarian, public	1970-10-21	c81755dbbbea9d5c77f094348a7579be	1371816893	40.49581	-74.196111	0
4	2020-06-21 12:15:15	3.591920e+15	fraud_Haley Group	misc_pos	60.05	Brian	Williams	M	32941 Krystal Mill Apt. 552	Titusville	28.5697	-80.8191	54767	Set designer	1987-07-25	2159175b9efe66dc301f149d3d5abf8c	1371816915	28.812397999999998	-80.883061	0
5	2020-06-21 12:15:17	3.526826e+15	fraud_Johnston-Casper	travel	3.19	Nathan	Massey	M	5783 Evan Roads Apt. 465	Falmouth	44.2526	-85.017000000000001	1126	Furniture designer	1955-07-06	57ff021bd3f328f8738bb5135c302a31b	1371816917	44.959148	-85.884734	0
6	2020-06-21 12:15:37	3.040768e+13	fraud_Daugherty LLC	kids_pets	19.55	Danielle	Evans	F	76752 David Lodge Apt. 064	Brenport	42.1939	-76.7361	520	Psychotherapist	1991-10-13	798db04aace84febd0384f1a7c404cde93	1371816937	41.747157	-77.584197	0
7	2020-06-21 12:15:44	2.131807e+14	fraud_Romaguera Ltd	health_fitness	133.93	Kayla	Sutton	F	010 Weaver Land	Carlotta	40.507	-123.9743	1128	Therapist, occupational	1951-01-15	17003d7ce5344403eadb10c4750e020e5	1371816944	41.499458000000004	-124.888729	0
8	2020-06-21 12:15:50	3.589290e+15	fraud_Reichel LLC	personal_care	10.37	Paula	Estrada	F	350 Stacy Glens	Spencer	43.7557	-97.5936	343	Development worker, international aid	1972-03-05	8be473a64059c6146ea55ace73e7ca2	1371816950	44.495498	-97.728453	0
9	2020-06-21 12:16:10	3.596357e+15	fraud_Goyette, Howell and Collier	shopping_pos	4.37	David	Everett	M	4138 David Fall	Morristale	41.0001	-78.2357	3688	Advice worker	1973-05-27	71af1a4150d1ce51019367622e08e784e	1371816970	41.546067	-78.120238	0
10	2020-06-21 12:16:11	3.546898e+15	fraud_Kilback Group	food_dining	66.54	Kayla	Obrien	F	7621 Robert Port Suite 343	Prairie Hill	31.6591	-96.8094	263	Barrister	1956-05-30	a791513227c42409960ba03a47801e3bd	1371816971	31.782919	-96.366185	0

5

Рисунок 5 — Пятый слайд презентации

2.Б. Источник данных

Столбцы:

- trans_date_trans_time — дата и время транзакции;
- cc_num — номер кредитной карты клиента;
- merchant — название торговой точки;
- category — категория торговой точки;
- amt — сумма транзакции;
- first — имя владельца кредитной карты;
- last — фамилия владельца кредитной карты;
- gender — пол владельца кредитной карты;
- street — улица адреса владельца кредитной карты;
- city — город владельца кредитной карты;
- state — штат владельца кредитной карты;
- zip — почтовый индекс владельца кредитной карты;
- lat — широта местоположения владельца кредитной карты;
- long — долгота местоположения владельца кредитной карты;
- city_pop — население города владельца кредитной карты;
- job — профессия владельца кредитной карты;
- dob — дата рождения владельца кредитной карты;
- trans_num — номер транзакции;
- unix_time — время транзакции в формате UNIX;
- merch_lat — широта местоположения торговой точки;
- merch_long — долгота местоположения торговой точки;
- is_fraud —целевая переменная.

6

Рисунок 6 — Шестой слайд презентации

3.А. Инструменты анализа

Glarus BI

Библиотеки языка **R**:

- tidyverse (включая dplyr, ggplot2) – обработка и визуализация данных
- lubridate – работа с датой и временем
- praznik – расчёт взаимной информации (Mutual Information)
- Information – расчёт Information Value (IV) и WoE
- corrplot – визуализация корреляционной матрицы
- maps, sf – построение географических тепловых карт
- keras (с TensorFlow) – создание и обучение нейронной сети
- rmarkdown (и knitr) – автоматическая генерация отчётов





7

Рисунок 7 — Седьмой слайд презентации

3.Б. Инструменты анализа

Критерий	R	Glarus BI
Основное назначение	Статистический анализ, машинное обучение	Бизнес-аналитика, интерактивные дашборды
Подход	Программирование	No-code
Статистические методы	t-тест, хи-квадрат, MI, IV, регрессии, нейронные сети и др.	Базовые агрегации (сумма, среднее, счёт)
Машинное обучение	Полноценное: нейронные сети (keras), случайный лес, SVM, градиентный бустинг	Отсутствует
Автоматизация отчётности	RMarkdown	Экспорт дашбордов в PDF/PNG
Гибкость визуализации	Полный контроль (ggplot2, слои, темы, любые модификации)	Высокая – библиотека готовых виджетов (карты, деревья, графики), но в рамках интерфейса
Использование	Для исследовательского анализа, моделирования и технических отчётов	Для оперативных дашбордов и презентаций агрегированных результатов руководству

8

Рисунок 8 — Восьмой слайд презентации

4. Предобработка данных

- Проверка на пропуски и дубликаты – отсутствуют
- Коррекция типов данных (числовые, даты, факторы)
- Создание новых признаков:
  - месяц, день недели, час транзакции
  - возраст клиента на момент операции
  - расстояние между клиентом и торговой точкой (формула гаверсинуса)
- Тригонометрическое преобразование часа (hour_sin, hour_cos) для учёта цикличности

```
Количество дубликатов:  0
Количество пропусков:  0
```

age	month	day_of_week	hour	purchase_dist
<dbl>	<dbl>	<dbl>	<int>	<dbl>
52	6	7	12	24.56159
30	6	7	12	104.92562
49	6	7	12	59.08037
32	6	7	12	27.69871

```
Ошибка в широте клиента:  FALSE
Ошибка в широте торговой точке:  FALSE
Ошибка в долготе клиента:  FALSE
Ошибка в долготе торговой точке:  FALSE
Ошибка в возрасте:  FALSE
Ошибка в сумме:  FALSE
```

9

Рисунок 9 — Девятый слайд презентации

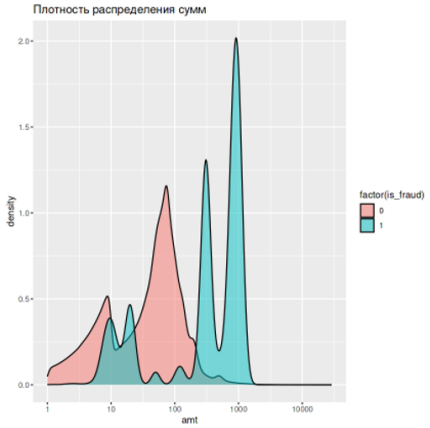
5.А. Исследовательский анализ данных

О чём график:

Сравнение распределения сумм легальных и мошеннических операций (логарифмическая шкала).

Мини-выводы:

- Большинство легальных транзакций имеют сумму до 200$.
- Мошеннические операции, напротив, концентрируются в диапазоне 900–1100,хотявстречаютсяимелкие(5–50,хотявстречаютсяимелкие(5–50).



10

Рисунок 10 — Десятый слайд презентации

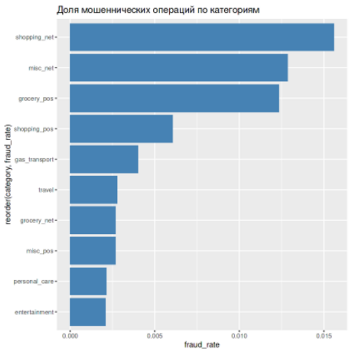
5.Б. Исследовательский анализ данных

О чём график:

Топ-10 категорий торговых точек с наибольшей долей мошеннических операций.

Мини-выводы:

- Лидируют онлайн-категории (например, «online shopping», «digital goods») – мошенники предпочитают бесконтактные каналы.
- Продуктовые магазины (офлайн) также входят в тройку – возможно, из-за кражи физических карт или данных с чеков.



11

Рисунок 11 — Одиннадцатый слайд презентации

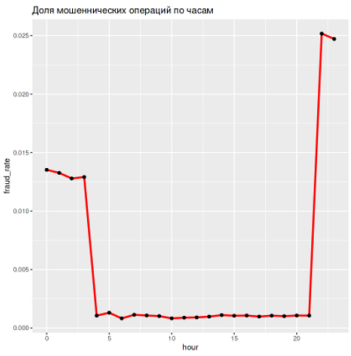
5.B. Исследовательский анализ данных

О чём график:

Линейный график, показывающий долю мошеннических транзакций (в % от всех операций) в зависимости от часа суток.

Мини-выводы:

- Мошенническая активность резко возрастает в ночное время – с 22:00 до 3:00.
- В этот период доля фрода достигает 2,5%, тогда как в остальные часы стабильно держится на уровне около 0,1%.
- Время совершения транзакции – сильный предиктор мошенничества, что обосновывает включение циклических признаков hour_sin и hour_cos в модель.



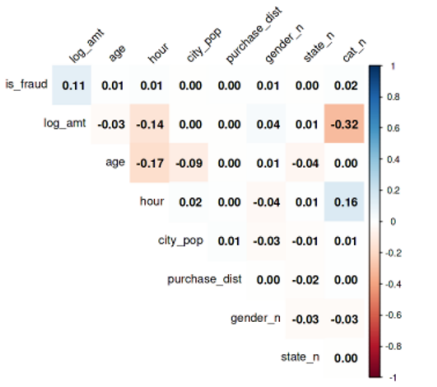
12

Рисунок 12 — Двенадцатый слайд презентации

6. Корреляционный анализ

Матрица корреляции Пирсона показала слабую линейную связь между признаками и is_fraud (только log_amt ~0.1)

Причина: нелинейный характер зависимостей



13

Рисунок 13 — Тринадцатый слайд презентации

7. Отбор признаков

MI – улавливает любые типы зависимостей (не только линейные)
IV – банковский стандарт оценки предсказательной силы

Результаты (топ признаков):

- amt (IV = 3.30) – абсолютный лидер
- hour (IV = 1.7)
- merchant и category (IV ~0.7–0.8)

Признаки, отобранные для модели: log_amt, category, hour_sin, hour_cos, age

	Variable	IV	MI
1	amt	3.3002934364	1.027518e-02
2	hour	1.7225413122	4.510389e-03
3	merchant	0.8324633481	2.068471e-03
4	category	0.7487471783	1.882160e-03
5	month	0.0953104676	2.508467e-04
6	age	0.0508740173	1.464918e-04
7	state	0.0375376470	9.782743e-05
8	day_of_week	0.0273657812	6.877930e-05
9	gender	0.0064967870	1.644473e-05
10	city_pop	0.0055295475	2.285070e-05
11	purchase_dist	0.0005140231	4.271892e-06

14

Рисунок 14 — Четырнадцатый слайд презентации

8. Проверка гипотез

t-тест Уэлча

H_0 : Средние суммы легальных и мошеннических транзакций одинаковы.

H_1 : Средние суммы существенно различаются.

Отвергаем H_0. Мошеннические транзакции в среднем имеют существенно бóльшую сумму, чем легальные.

```
        Welch Two Sample t-test

data:  amt by is_fraud
t = -106.53, df = 8162.8, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -470.8748 -453.8595
sample estimates:
mean in group 0 mean in group 1
       67.62292       529.99007
```

```
        Pearson's Chi-squared test

data:  contingency_table
X-squared = 7092.7, df = 13, p-value < 2.2e-16
```

Критерий хи-квадрат Пирсона

H_0: Категория покупки и мошенничество не связаны.

H_1 : Между категорией и фродом существует статистически значимая связь.

Отвергаем H_0. Определённые категории являются более рискованными.

15

Рисунок 15 — Пятнадцатый слайд презентации

9. Логистическая регрессия

Включены признаки: log_amt, category, hour_sin, hour_cos, age

Использованы веса классов для борьбы с дисбалансом

Коэффициенты показывают: рост суммы, ночные часы, онлайн-категории увеличивают риск

```
Call:
glm(formula = is_fraud ~ log_amt + category + hour_sin + hour_cos +
    age + gender, family = "binomial", data = model_data, weights = weights)

Coefficients:
                        Estimate Std. Error  z value Pr(>|z|)
(Intercept)           -2.835832   0.007951 -356.644  < 2e-16 ***
log_amt                1.119003   0.001786  627.035  < 2e-16 ***
categoryfood_dining    0.408766   0.010263   39.830  < 2e-16 ***
categorygas_transport  2.235429   0.009298  240.411  < 2e-16 ***
categorygrocery_net    1.847758   0.011550  159.974  < 2e-16 ***
categorygrocery_pos    1.594010   0.008728  182.637  < 2e-16 ***
categoryhealth_fitness 0.832857   0.010446   79.729  < 2e-16 ***
categoryhome          -0.077348   0.009802   -7.891 2.99e-15 ***
categorykids_pets      1.051436   0.009524  110.394  < 2e-16 ***
categorymisc_net       1.458636   0.010033  145.390  < 2e-16 ***
categorymisc_pos       1.001041   0.010374  173.680  < 2e-16 ***
categorypersonal_care  1.250180   0.009818  127.330  < 2e-16 ***
categoryshopping_net   1.548819   0.009097  170.265  < 2e-16 ***
categoryshopping_pos   0.948729   0.009381  101.136  < 2e-16 ***
categorytravel         2.454956   0.012126  202.459  < 2e-16 ***
hour_sin              -0.488893   0.003613 -113.160  < 2e-16 ***
hour_cos               1.723441   0.002640  656.651  < 2e-16 ***
age                    0.001589   0.001580   38.971  < 2e-16 ***
genderM               -0.130029   0.003247  -40.050  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 4448047  on 1684293  degrees of freedom
Residual deviance: 2494909  on 1684275  degrees of freedom
AIC: 2489953

Number of Fisher Scoring iterations: 8
```

(Intercept): 0.058669708387715 **log_amt:** 3.06455573598316 **categoryfood_dining:** 1.50496021501438 **categorygas_transport:** 9.35049119282301 **categorygrocery_net:** 6.34557399513426 **categorygrocery_pos:** 4.92345249472261 **categoryhealth_fitness:** 2.29988020190012 **categoryhome:** 0.925567318915518 **categorykids_pets:** 2.86175643261948 **categorymisc_net:** 4.30009088220949 **categorymisc_pos:** 6.06079517714263 **categorypersonal_care:** 5.49097210195782 **categoryshopping_net:** 4.70590849913733 **categoryshopping_pos:** 2.58242598207129 **categorytravel:** 11.6459167084388 **hour_sin:** 0.664385561442344 **hour_cos** 5.66009707855376 **age:** 1.06352474685442 **genderM:** 0.877007012247174

16

Рисунок 16 — Шестнадцатый слайд презентации

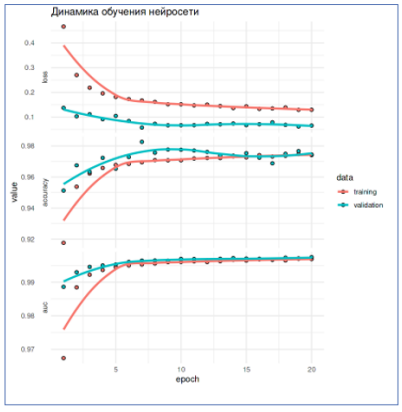
10. Классификация

Полносвязная нейронная сеть прямого распространения

```
      loss    accuracy         auc
0.06205927 0.97652549 0.99721658
```

- **AUC = 0.997** – исключительная разделяющая способность
- **Accuracy = 97.6%**
- **Recall = 98.2%** – выявлено 1672 из 1702 мошеннических операций в тесте
- **False Positive Rate ~2.6%** – допустимый компромисс в fraud-детекции
- Матрица ошибок: 98.2% фрода распознано, только 1.8% пропущено

Actual	Predicted 0	1
0	310944	8213
1	30	1672



17

Рисунок 17 — Семнадцатый слайд презентации

11. Визуализация в Glarus BI

Интерактивный дашборд в Glarus BI

- Карта плотности мошенничества по штатам США (пузырьковая диаграмма)
- Древовидная карта – топ категорий торговых точек по числу фрод-операций
- Линейный график – пик мошенничества с 22:00 до 03:00
- Кольцевая диаграмма – распределение пострадавших по полу

Вывод: Дашборд позволяет оперативно мониторить ключевые индикаторы риска без написания кода.



18

Рисунок 18 — Восемнадцатый слайд презентации

12. Выводы

Ключевые результаты:

- Ключевые предикторы мошенничества: сумма транзакции (IV = 3,30), час операции (IV = 1,7), категория покупки
- Нейросетевая модель: AUC = 0,997, Recall = 98,2% (выявлено 1672 из 1702 фрод-операций)
- Связка R + Glarus BI — полный аналитический конвейер (исследование + интерактивные дашборды)



Практическая значимость:

Внедрение в системы anti-fraud для автоматической блокировки подозрительных транзакций в реальном времени

Перспективы:

- Сравнение с другими моделями (случайный лес, градиентный бустинг, SVM)
- Байесовская оптимизация гиперпараметров

19

Рисунок 19 — Девятнадцатый слайд презентации

Спасибо за внимание! Доклад окончен

20

Рисунок 20 — Двадцатый слайд презентации